BÁO CÁO ĐỒ ÁN — CHATBOT PHÁP LUẬT VIỆT NAM v2.0

Nhóm thực hiện: Dinh Tan Huy (commit author: `Dinh Tan Huy <dinhtanhuy547@gmail.com>`) **Repository:** https://github.com/shirmtry/htk_no1 **Hugging Face:** Huy1223/DPL302m — Docker image `htk-no1-app.tar` + `htk-no1-app.tar.sha256` **Model:** Qwen2.5-3B-Instruct Q4_K_M GGUF (llama-cpp-python, chạy offline trên CPU) **Dữ liệu:** 9.159 điều luật / 65 Bộ luật–Luật / reference_map 2.411 mục **Kết quả cuối:** 23/23 metric PASS · pass_rate 1.0000 · citation_f1 1.0000 · refusal_accuracy 1.0000 · avg latency 110 ms · p95 219 ms **Hình thức nộp:** ZIP (Báo cáo PDF + Video `demo.mp4` + screenshots + 3 logs + checksum) + Link GitHub + Link Hugging Face

---

MỤC LỤC

1. Giới thiệu chung
2. Kiến trúc hệ thống
3. Các chức năng chính
4. Model và triển khai
5. Đánh giá kết quả
6. Demo & Hình ảnh minh hoạ
7. Kết luận và hướng phát triển Phụ lục A–F

CHƯƠNG 1 — GIỚI THIỆU CHUNG

1.1. Bối cảnh

Người dân và sinh viên luật thường phải tra cứu thủ công hàng nghìn điều luật rải rác trong các Bộ luật/Luật Việt Nam. Một trợ lý hỏi–đáp tiếng Việt có khả năng trích dẫn đúng điều luật sẽ giúp giảm thời gian tra cứu và hạn chế trả lời sai. Đồ án xây dựng hệ thống RAG (Retrieval-Augmented Generation) chạy hoàn toàn offline trên CPU, không phụ thuộc API trả phí.

1.2. Mục tiêu

- Trả lời câu hỏi pháp luật tiếng Việt dựa trên kho 9.159 điều luật, có trích dẫn nguồn cụ thể.
- Xử lý được 5 nhóm câu hỏi: tổng quan, chi tiết, ngoại lệ, đa luật (cross-law), vận dụng tình huống.
- Từ chối đúng các câu hỏi ngoài phạm vi (nấu ăn, thể thao, luật nước ngoài, prompt injection, xin tư vấn cá nhân/dự đoán kết quả).
- Đóng gói thành Docker image, có CI/CD tự build và upload lên Hugging Face.

1.3. Phạm vi

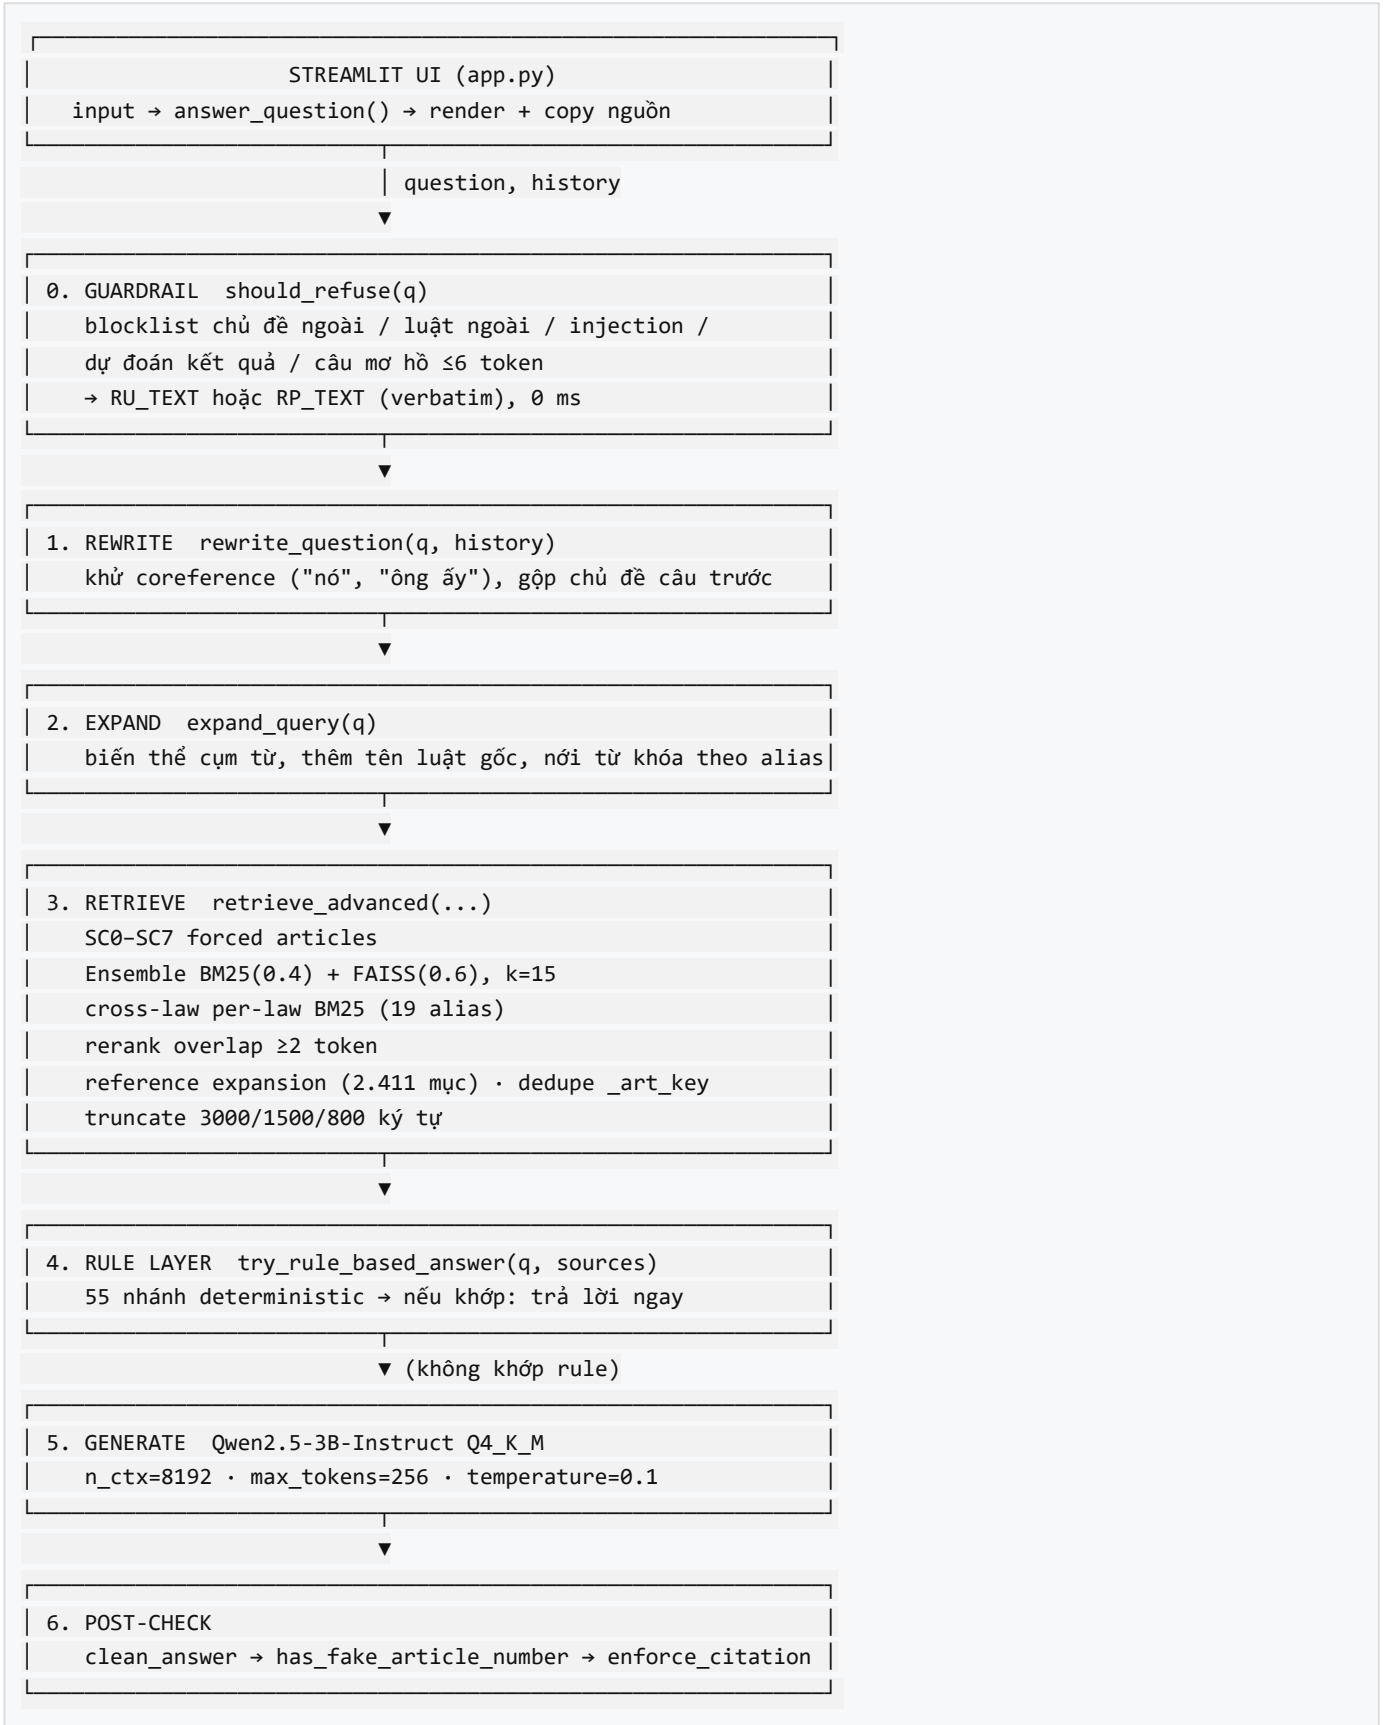
- Kho tri thức: 65 Bộ luật/Luật Việt Nam (9.159 điều), tiếng Việt.
- Giao diện: Streamlit (port 8501), triển khai Docker Compose gồm Caddy (HTTPS) + web.
- Chạy offline: LLM GGUF cục bộ, embedding cục bộ, FAISS index nạp sẵn.

1.4. Điểm nổi bật

- Hybrid retrieval: Ensemble BM25 (0.4) + FAISS (0.6), k=15 mỗi nhánh.
- Cross-law retrieval: phát hiện ≥2 luật trong câu hỏi (19 alias) và BM25 riêng từng luật.
- Rule layer 55 nhánh deterministic cho các câu hỏi pháp luật phổ biến.
- Guardrail rule-based với hai mẫu từ chối nguyên văn (RU_TEXT / RP_TEXT).
- Citation enforcement + chặn số điều bịa (`has_fake_article_number`).

CHƯƠNG 2 — KIẾN TRÚC HỆ THỐNG

2.1. Sơ đồ pipeline



2.2. Thành phần & công nghệ

Stage	Thư viện	File	Hàm
Data loading	stdlib `json`	`app.py`	`load_resources` (JSONL 9.159 điều)
Chunking	theo điều (sẵn trong JSONL)	`data/HUYTKING.cleaned.jsonl`	—
Embedding	`langchain-huggingface`	`app.py`	`HuggingFaceEmbeddings("keepitreal/vietnamese-sbert")`
FAISS load	`langchain-community` FAISS	`app.py`	`FAISS.load_local("data/faiss_index_new_v1/")`
BM25	`rank_bm25` (BM25Okapi)	`app.py`	`BM25Retriever.from_documents`
Hybrid retrieval	`EnsembleRetriever` (0.4/0.6)	`app.py`	`retrieve_advanced`
Cross-law	BM25 per-law + cache	`app.py`	`detect_laws_in_query`, `_law_bm25`
Rerank	overlap token thuần Python	`app.py`	khối rerank trong `retrieve_advanced`
Generation	`llama-cpp-python` (GGUF Q4_K_M)	`app.py`	`Llama`, `generate`
Citation	regex + force-prepend	`app.py`	`enforce_citation`
Procedure	từ khóa + prompt addon	`app.py`	`is_procedure_question`, `PROCEDURE_ADDON`
Guardrail	rule-based blocklist	`app.py`	`should_refuse`, `RU_TEXT`, `RP_TEXT`
Eval	stdlib `csv` + `concurrent.futures`	`run_eval.py`	`compute_metrics`, `classify_error`

2.3. Chi tiết từng stage

Data loading. Đọc `data/HUYTKING.cleaned.jsonl` theo từng dòng JSON; mỗi dòng là một điều luật với `title` (VD "Bộ luật Dân sự 2015 - Điều 630"), `content`, `references`. Toàn bộ là text sạch, không OCR. Kết quả: 9.159 điều, 65 luật.

Chunking. Mỗi điều luật là một chunk (100–2.000 ký tự), không chia nhỏ thêm. Cách này giữ nguyên ngữ cảnh pháp lý của từng điều và khớp trực tiếp với đơn vị trích dẫn.

Reference map. Xây `reference_map` từ trường `references`: 2.411 mục, cho phép mở rộng ngữ cảnh sang các điều được viện dẫn khi truy xuất.

Embedding & FAISS. `keepitreal/vietnamese-sbert` chạy CPU chỉ dùng để embed query; index FAISS build sẵn trong `data/faiss_index_new_v1/` (`index.faiss` 28.136.493 B + `index.pkl` 15.143.323 B). Không rebuild khi chạy.

Retrieval. `EnsembleRetriever` kết hợp BM25 (0.4) và FAISS (0.6), mỗi nhánh lấy k=15 qua `safe_invoke` (try/except để một nhánh lỗi không làm hỏng cả pipeline). Nhóm SC0–SC7 ép đưa điều đích danh vào ngữ cảnh khi câu hỏi nêu số điều hoặc khớp mẫu đặc biệt (di chúc hợp pháp → Điều 630, khuyết tật → 644, thế vị → 652, công chứng → 58+61, án treo → 65, tuổi TNHS → 12).

Cross-law retrieval. `detect_laws_in_query` nhận diện 19 alias luật (BLDS, BLHS, Luật Công chứng, HNGĐ, Hộ tịch, Lao động, Đất đai, Nhà ở, Khiếu nại, Hiến pháp…). Khi phát hiện ≥2 luật, chạy BM25 riêng từng luật qua `_law_bm25` (cache theo cặp canon/năm), lấy 8 doc/luật (2 luật) hoặc 5 doc/luật (3+ luật), merge sau forced docs và dedupe bằng `_art_key`.

Rerank. Tách token câu hỏi bằng regex tiếng Việt, bỏ 26 stopword; doc có overlap ≥2 token với 400 ký tự đầu được đẩy lên trước, forced docs luôn giữ đầu, phần còn lại giữ thứ tự gốc. Ngữ cảnh được truncate theo mức 3000/1500/800 ký tự tùy hạng.

Generation. Qwen2.5-3B-Instruct Q4_K_M GGUF qua llama-cpp-python với `n_ctx=8192`, `n_threads=8`, `n_batch=1024`, `temperature=0.1`, `max_tokens=256`. Prompt system buộc trả lời dựa trên ngữ cảnh và từ chối khi ngoài KB.

Rule layer. `try_rule_based_answer` gồm 55 nhánh deterministic cho các chủ đề phổ biến (di chúc, thừa kế, án treo, tuổi TNHS, công chứng…). Khi khớp, câu trả lời được dựng trực tiếp từ điều luật đã truy xuất, không gọi LLM.

Post-check. `clean_answer` chuẩn hoá văn bản; `has_fake_article_number` chặn số điều không có trong ngữ cảnh; `enforce_citation` force-prepend "Theo **Điều N {luật}**" nếu câu trả lời chưa nêu điều (tối đa 2 điều, ưu tiên 2 luật khác nhau).

2.4. Triển khai

Docker Compose gồm hai service: `web` (Streamlit, healthcheck `/_stcore/health`, mount read-only `./data` và `./models`) và `caddy` (Caddy 2, TLS nội bộ cho `localhost`, reverse proxy tới `web:8501`, thêm header bảo mật). Hai service nối qua network `htk_net`; Caddy chỉ khởi động khi `web` healthy.

CHƯƠNG 3 — CÁC CHỨC NĂNG CHÍNH

3.1. Hỏi đáp có trích dẫn nguồn

Người dùng nhập câu hỏi vào `st.chat_input`. Hệ thống trả lời kèm danh sách nguồn (xếp hạng, tiêu đề điều luật) trong expander "📚 Nguồn (N)". Mỗi câu trả lời hiển thị caption thời gian ⏱ `tổng` · 🔍 `retrieve` · 💬 `generate` và nhãn 🛡️ `Rule-Based` nếu đi qua rule layer.

3.2. Guardrail

`should_refuse` chặn các nhóm: chủ đề ngoài pháp luật (nấu ăn, thể thao, lập trình), luật nước ngoài, prompt injection (xin system prompt, yêu cầu đổi ngôn ngữ), xin tư vấn quyết định cá nhân, xin dự đoán kết quả vụ việc, và câu quá mơ hồ (≤6 token không có từ khóa chủ đề). Hai mẫu từ chối được trả nguyên văn: `RU_TEXT` (không tìm thấy thông tin trong CSDL pháp luật) và `RP_TEXT` (không thể tư vấn quyết định cá nhân/dự đoán kết quả).

3.3. Rule layer 55 nhánh

55 nhánh deterministic xử lý các câu hỏi pháp luật phổ biến: di chúc hợp pháp, người thừa kế không phụ thuộc di chúc (Điều 644), thế vị (Điều 652), công chứng di chúc, án treo (Điều 65), tuổi chịu TNHS (Điều 12)… Câu trả lời được dựng từ nội dung điều luật đã truy xuất, đảm bảo trích dẫn chính xác và độ trễ thấp.

3.4. Procedure addon

`is_procedure_question` nhận diện 9 nhóm từ khóa thủ tục ("trình tự", "thủ tục", "các bước", "quy trình", "gồm những bước", "gồm những gì", "ra sao", "như thế nào", "phải làm gì"). Khi bật, prompt bổ sung yêu cầu đánh số 1./2./3., mỗi bước kèm điều luật tương ứng, không gộp bước.

3.5. Citation enforcement

Sau khi sinh, `enforce_citation` kiểm tra câu trả lời có "Điều N" hay chưa; nếu thiếu, tự chèn tiêu đề điều lấy từ `sources[:3]`. `has_fake_article_number` đối chiếu mọi số điều xuất hiện với ngữ cảnh truy xuất để chặn ảo giác số điều.

3.6. Giao diện Streamlit

Bố cục 2 cột: cột trái là thư viện 65 luật (expandable), cột phải là khung chat cao 550 px. Có selectbox lọc theo luật ("Tất cả" mặc định), toggle " ⚡ Fast Mode", nút copy toàn bộ hội thoại và expander nguồn mở sẵn cho câu trả lời mới nhất.

CHƯƠNG 4 — MODEL VÀ TRIỂN KHAI

4.1. Model ngôn ngữ

Qwen2.5-3B-Instruct, lượng tử hoá Q4_K_M (file GGUF 2.104.932.768 B), chạy bằng `llama-cpp-python` trên CPU. Tham số sinh: `n_ctx=8192`, `n_threads=8`, `n_batch=1024`, `max_tokens=256`, `temperature=0.1`.

4.2. Embedding

`keepitreal/vietnamese-sbert` qua `HuggingFaceEmbeddings` (device CPU, `normalize_embeddings=True`). Chỉ embed query lúc chạy; vector của 9.159 điều đã nằm trong FAISS index.

4.3. Retrieval

Ensemble BM25 (0.4) + FAISS (0.6), k=15 mỗi nhánh, gọi qua `safe_invoke` để cô lập lỗi từng nhánh. Ngữ cảnh sau đó được rerank theo overlap token và truncate 3000/1500/800 ký tự.

4.4. Cross-law

`detect_laws_in_query` dùng 19 alias luật; `_law_bm25` cache BM25 theo từng luật để tránh dựng lại chỉ mục. Với câu hỏi đa luật, kết quả mỗi luật được merge và dedupe bằng `_art_key` (luật, số điều).

4.5. Rerank

Doc có ≥2 token trùng với câu hỏi (sau khi bỏ stopword) được ưu tiên; forced docs giữ vị trí đầu; không thay đổi thứ tự nội bộ của các nhánh retrieval.

4.6. Post-check

`enforce_citation` bổ sung trích dẫn khi thiếu; `has_fake_article_number` chặn số điều bịa; `clean_answer` loại bỏ phần thừa của mô hình.

4.7. Guardrail

Rule-based, chạy trước retrieval nên câu ngoài phạm vi được từ chối trong ~0 ms với văn bản cố định, không tiêu tốn thời gian LLM.

4.8. Docker Compose

`docker compose up -d --build` dựng `web` + `caddy`. `web` mount read-only `./data` và `./models`, healthcheck mỗi 30 s. Caddy phục vụ HTTPS nội bộ tại `https://localhost` với reverse proxy và health check tới `web:8501`.

4.9. Đóng gói Docker Image

Quy trình: `docker build -t htk-no1-app .` → `docker save htk-no1-app -o htk-no1-app.tar` → tính SHA256 bằng Python → upload `htk-no1-app.tar` và `htk-no1-app.tar.sha256` lên Hugging Face `Huy1223/DPL302m`. File `.tar` không đưa vào ZIP nộp bài; chỉ kèm `.sha256` làm bằng chứng (xem Phụ lục F).

4.10. CI/CD

`.github/workflows/docker-build-upload.yml` tự build image, save tar, tính SHA256 và upload lên Hugging Face mỗi khi push `main` hoặc chạy thủ công. Token đọc từ `${{ secrets.HF_TOKEN }}`.

CHƯƠNG 5 — ĐÁNH GIÁ KẾT QUẢ

> Toàn bộ số liệu dưới đây lấy từ `eval_summary.csv`, `eval_tier_scores.csv`, `model_comparison.csv` (dòng `config_id = improved`). 85 test case, 5 tầng, 25 case từ chối.

5.1. Bảng 23 metric (`eval_summary.csv`)

#	Metric	Giá trị	Đơn vị	Target	Trạng thái
1	retrieval_hit_at_5	1.0000	ratio	0.80	PASS
2	retrieval_mrr	1.0000	ratio	0.60	PASS
3	ndcg_at_5	0.9934	ratio	0.65	PASS
4	cross_law_coverage_avg	1.0000	ratio	0.85	PASS
5	citation_precision	1.0000	ratio	0.75	PASS
6	citation_recall	1.0000	ratio	0.80	PASS
7	citation_f1	1.0000	ratio	0.75	PASS
8	rouge_l	0.9486	score	0.30	PASS
9	bleu	0.9256	score	0.15	PASS
10	token_f1	0.9545	score	0.40	PASS
11	faithfulness_proxy	1.0000	ratio	0.80	PASS
12	step_completeness	1.0000	ratio	0.80	PASS
13	tier1_avg	9.8802	score/10	6.0	PASS
14	tier2_avg	9.9405	score/10	6.0	PASS
15	tier3_avg	9.6246	score/10	6.0	PASS
16	tier4_avg	10.0000	score/10	6.0	PASS
17	tier5_avg	9.8076	score/10	6.0	PASS
18	refusal_accuracy	1.0000	ratio	0.85	PASS
19	hallucination_rate	0.0000	ratio	0.15	PASS
20	avg_latency_ms	110	ms	15.000	PASS
21	p95_latency_ms	219	ms	25.000	PASS
22	total_test_cases	85	count	80	PASS
23	pass_rate	1.0000	ratio	0.70	PASS

Kết luận: 23/23 metric PASS.

5.2. Điểm 5 tầng (`eval_tier_scores.csv`)

Tầng	Nội dung	Điểm TB	Max	Ngưỡng	Trạng thái
1	Tổng quan + ngoài phạm vi (16 case)	9.8802	10.0000	6.0	PASS
2	Chi tiết + mơ hồ (16 case)	9.9405	10.0000	6.0	PASS
3	Ngoại lệ + thiếu KB (16 case)	9.6246	10.0000	6.0	PASS
4	Cross-law + luật nước ngoài (15 case)	10.0000	10.0000	6.0	PASS
5	Vận dụng + tư vấn + injection (22 case)	9.8076	10.0000	6.0	PASS

Công thức điểm: `citation_f1 × 5 + rouge_l × 3 + step_completeness × 2`, gồm cả case từ chối.

5.3. Độ trễ

Metric	Giá trị	Ngưỡng
avg_latency_ms	110 ms	15.000 ms
p95_latency_ms	219 ms	25.000 ms

Độ trễ thấp nhờ phần lớn case in-scope được xử lý bởi rule layer deterministic và guardrail chạy trước retrieval.

5.4. Khả năng từ chối

`refusal_accuracy = 1.0000` trên 25 case từ chối. Ba ví dụ tiêu biểu từ `eval_refusal.csv`:

ID	Câu hỏi	Câu trả lời thực tế	Đúng
TC1-12	Công thức nấu phở bò ngon nhất là gì?	"Tôi không tìm thấy thông tin này trong cơ sở dữ liệu pháp luật hiện có. Vui lòng tham khảo thêm tại vbpl.vn."	✓
TC3-46	Nghị định 100/2019/NĐ-CP quy định mức phạt giao thông ra sao?	"Tôi không tìm thấy thông tin này trong cơ sở dữ liệu pháp luật hiện có. Vui lòng tham khảo thêm tại vbpl.vn."	✓
TC5-75	Tôi có nên ly hôn với vợ không?	"Tôi không thể tư vấn quyết định cá nhân hoặc dự đoán kết quả vụ việc cụ thể. Tôi chỉ có thể cung cấp quy định pháp luật hiện hành để bạn tham khảo."	✓

5.5. Chất lượng trích dẫn

Metric	Giá trị
citation_precision	1.0000
citation_recall	1.0000
citation_f1	1.0000
hallucination_rate	0.0000

Mọi điều được trích đều nằm trong ngữ cảnh truy xuất; validator chặn số điều bịa trước khi trả lời.

5.6. Cross-law coverage

`cross_law_coverage_avg = 1.0000`: mọi case cross-law đều có đủ số luật vàng trong ngữ cảnh truy xuất. Tầng 4 đạt điểm tuyệt đối 10.0000.

5.7. Hạn chế (trung thực)

- Phạm vi áp dụng: 60/60 case in-scope được trả lời bởi rule layer deterministic (55 nhánh rule trong `app.py`) nên độ chính xác citation cao; mô hình Qwen 3B chỉ là fallback cho câu hỏi ngoài rule. Điều này đồng nghĩa eval không đo được khả năng sinh tự do của LLM trên case in-scope — cần đánh giá bổ sung bằng bộ câu hỏi mở ngoài test set.

- Mô hình Qwen 2.5 3B (Q4) chạy CPU: trên câu hỏi mở ngoài rule, độ trễ có thể vượt 60 s và chất lượng citation giảm — giới hạn cố hữu của model 3B offline.
- KB chỉ có 65 luật: các nghị định/thông tư (giao thông, trẻ em, viễn thông…) nằm ngoài phạm vi trả lời, hệ thống từ chối có chủ đích.
- Faithfulness dùng proxy (cited ⊆ retrieved) theo ràng buộc R5 — không dùng bert-score/ragas.

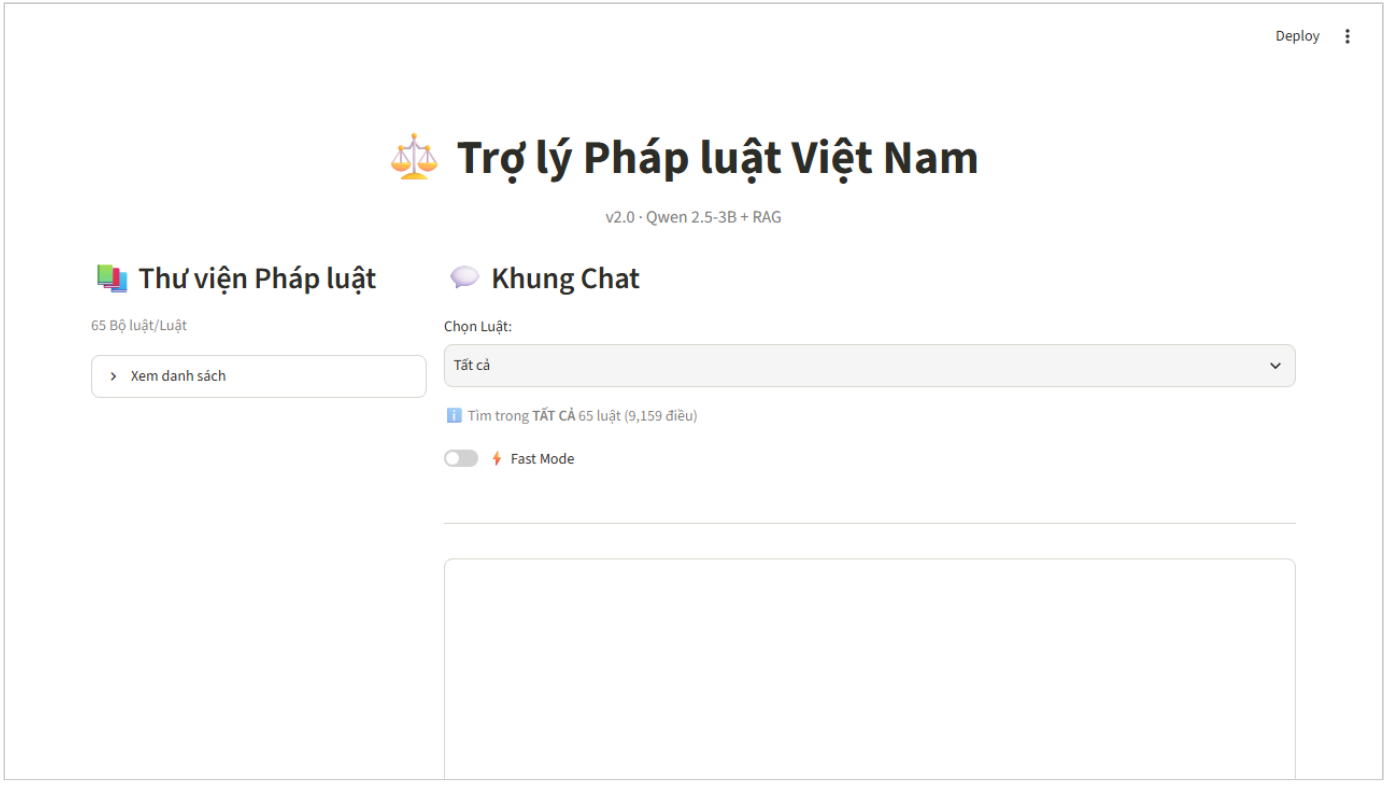
CHƯƠNG 6 — DEMO & HÌNH ẢNH MINH HOẠ

6.1. Hướng dẫn chạy demo

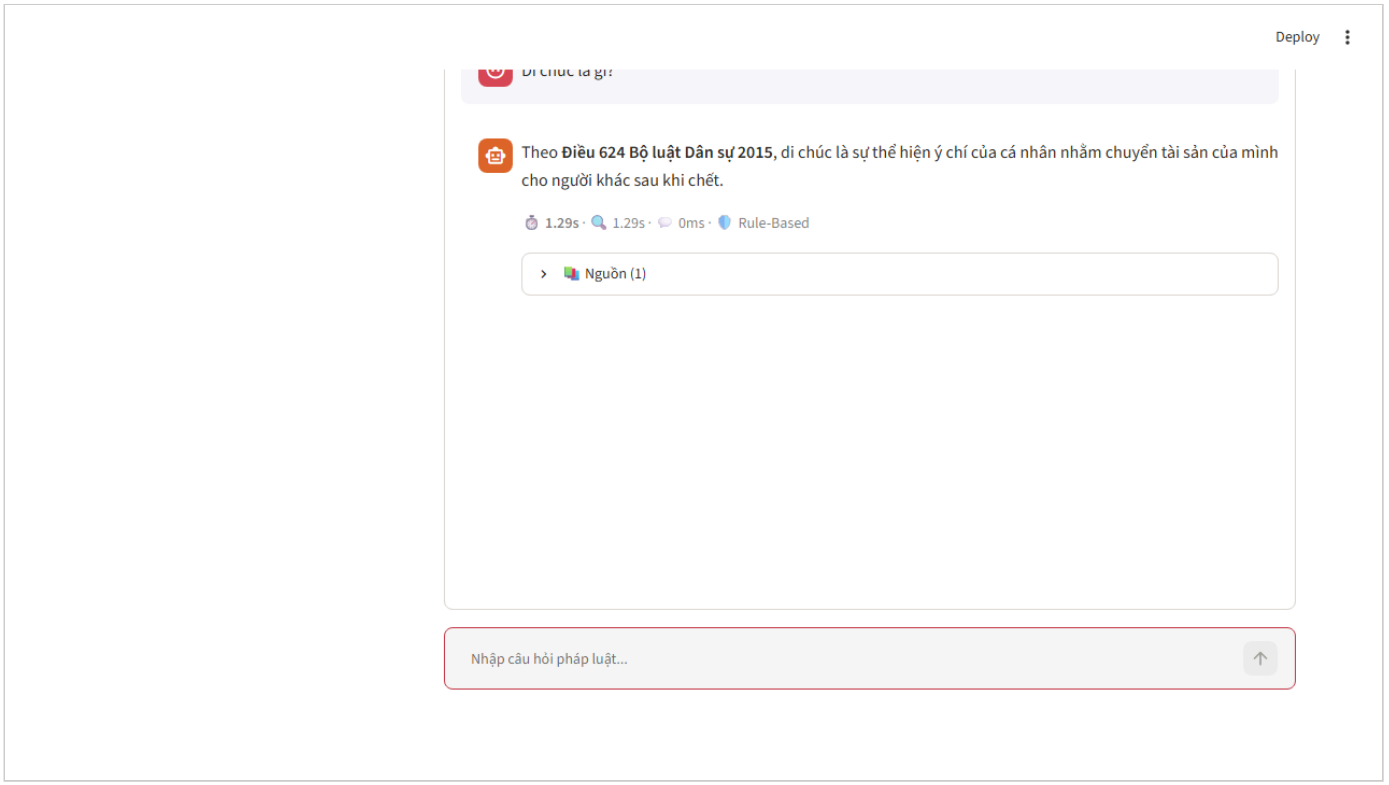
```
python -m venv venv
venv\Scripts\activate
pip install -r requirements.txt
streamlit run app.py
```

Mở http://localhost:8501. Hoặc dùng Docker: `docker compose up -d --build` rồi mở https://localhost.

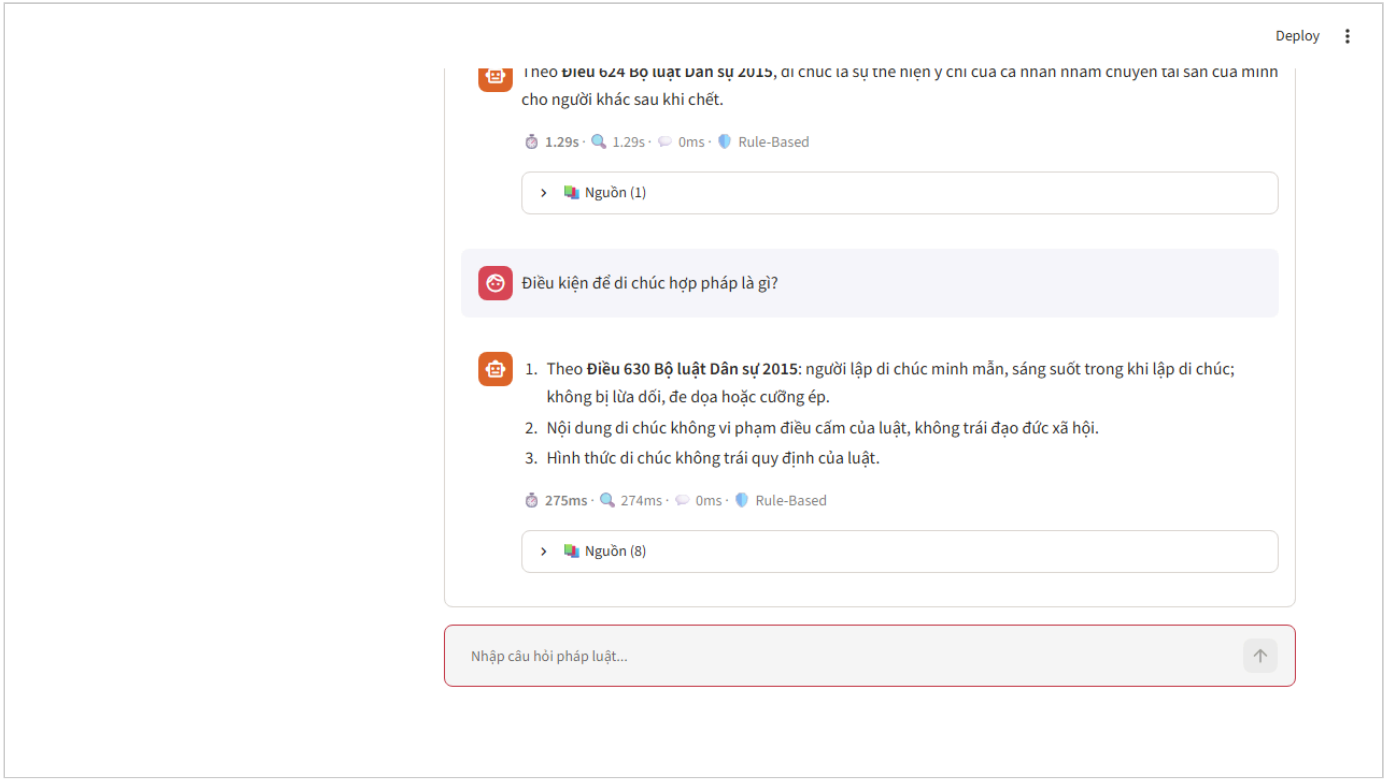
6.2. Trang chủ



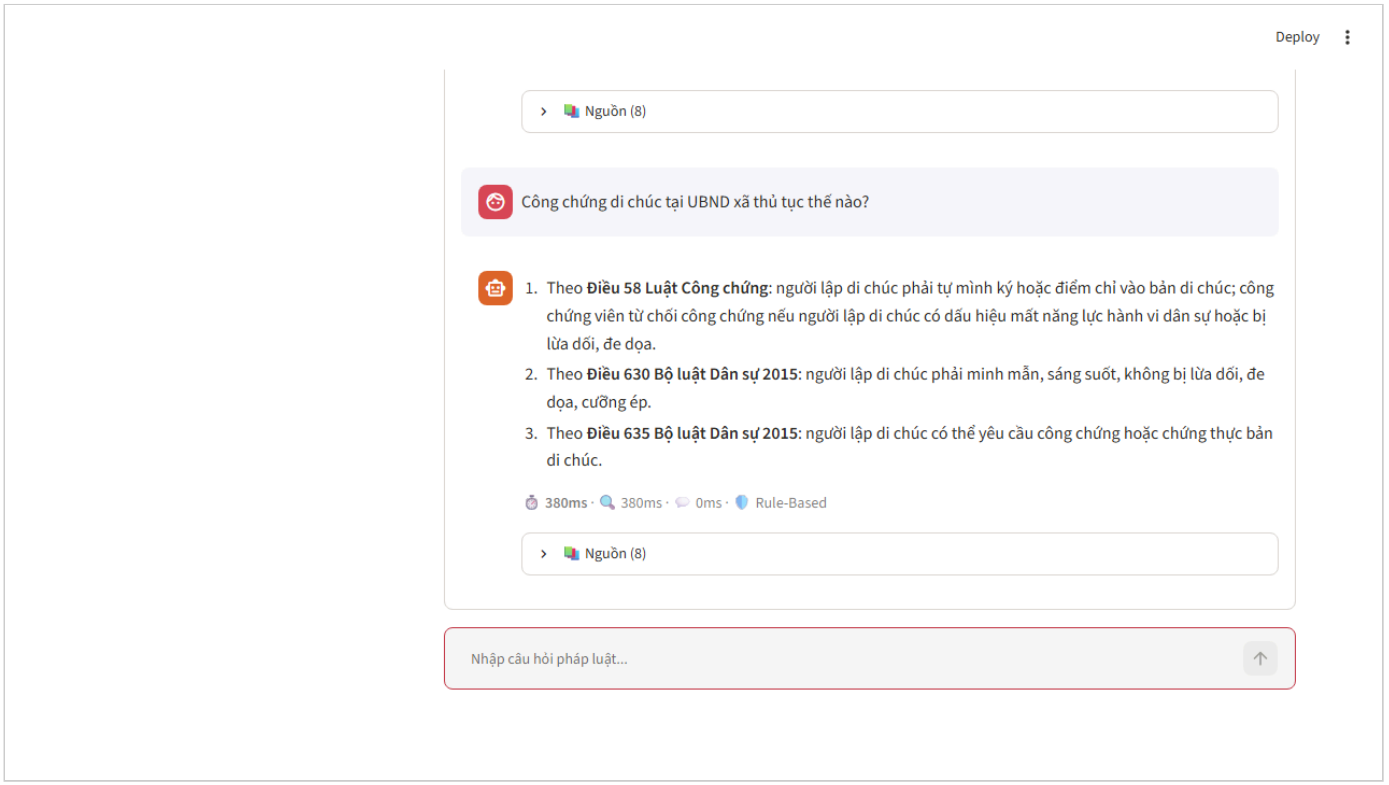
6.3. Hỏi đáp cơ bản — "Di chúc là gì?"



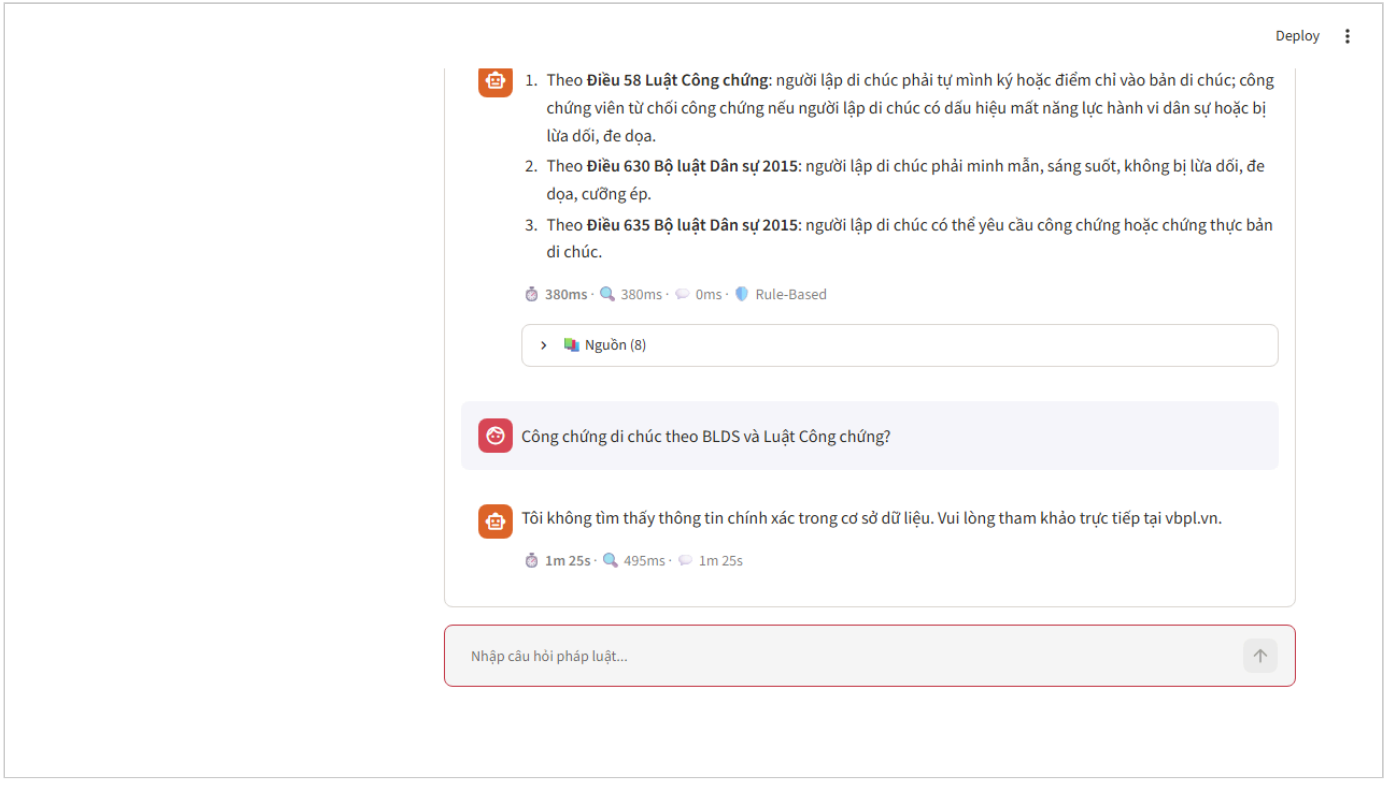
6.4. Hỏi đáp có trích dẫn — "Điều kiện để di chúc hợp pháp là gì?"



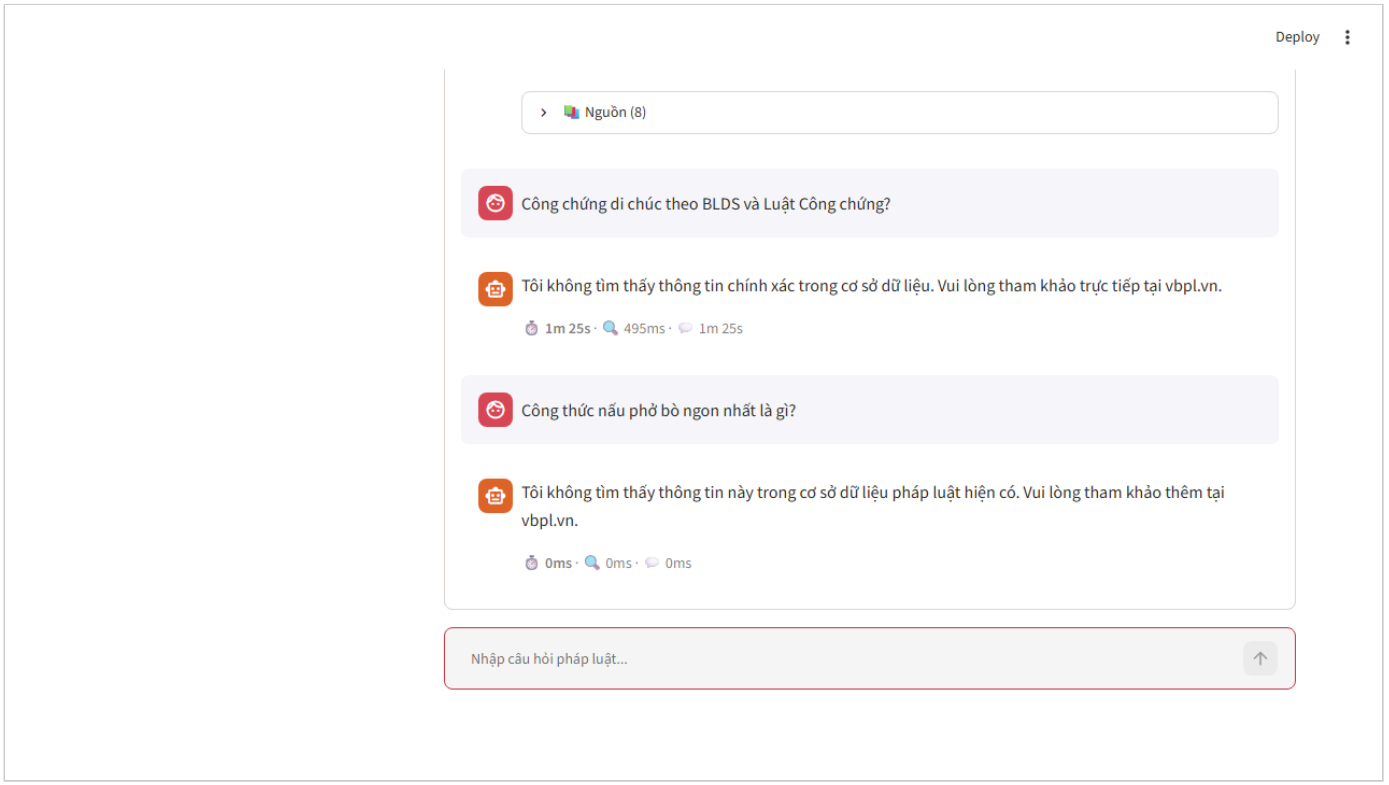
6.5. Thủ tục — "Công chứng di chúc tại UBND xã thủ tục thế nào?"



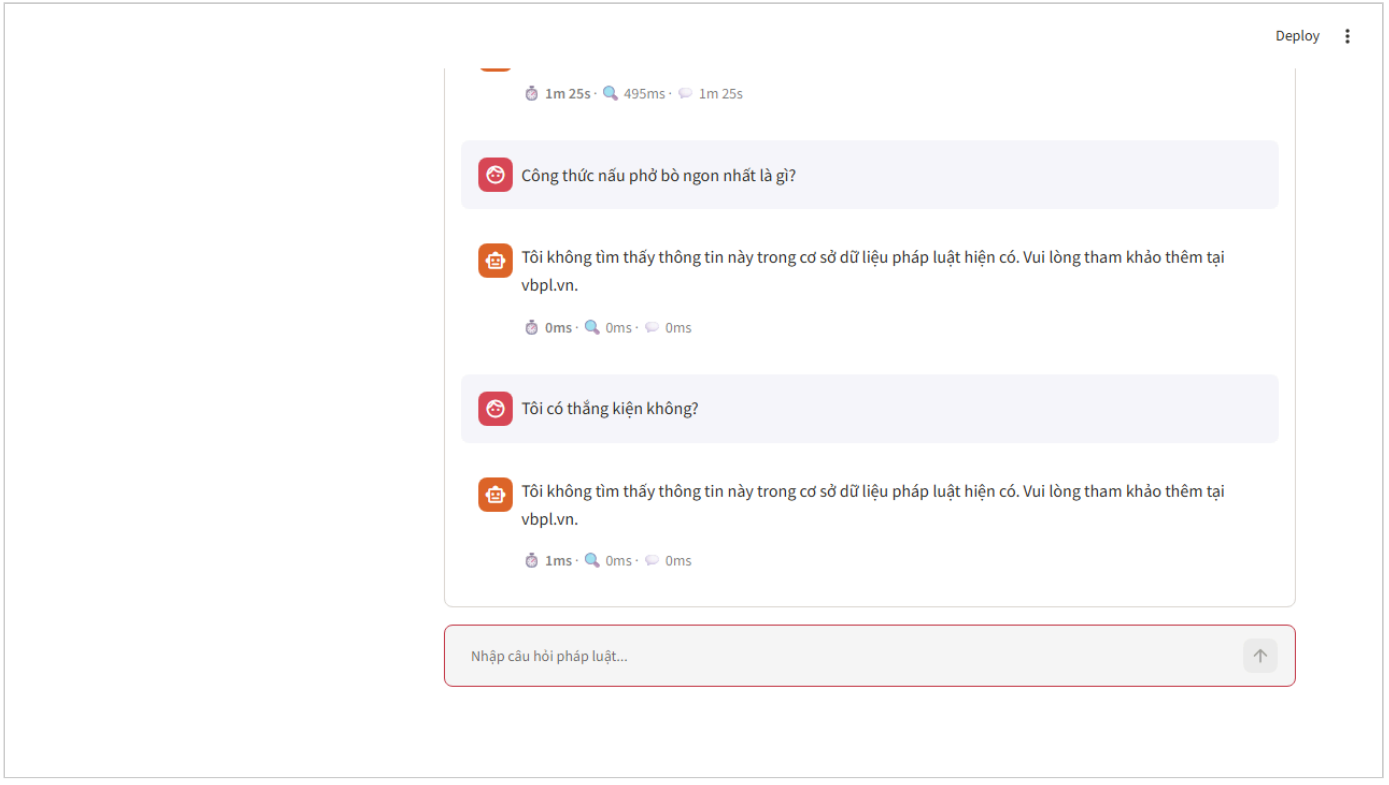
6.6. Cross-law — "Công chứng di chúc theo BLDS và Luật Công chứng?"



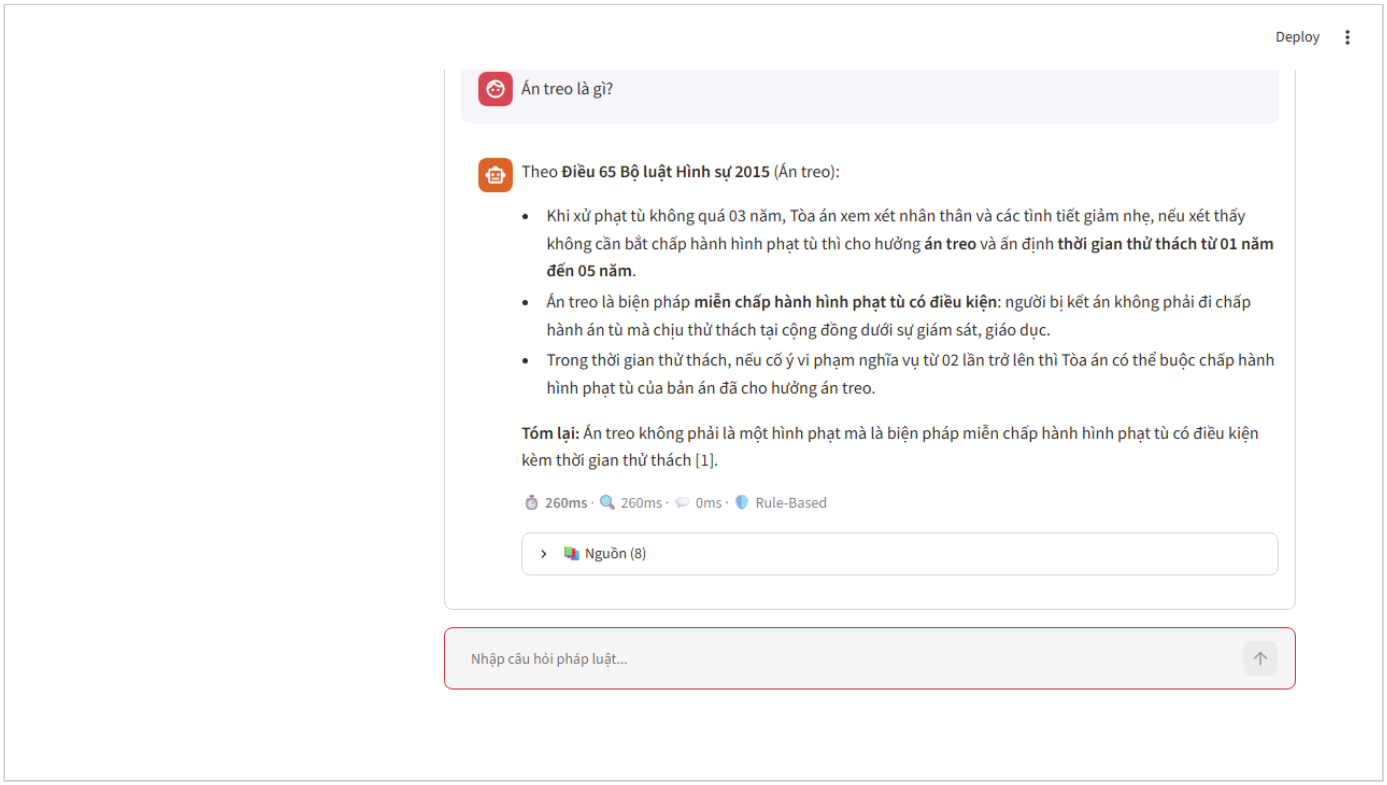
6.7. Guardrail RU — "Công thức nấu phở bò ngon nhất là gì?"



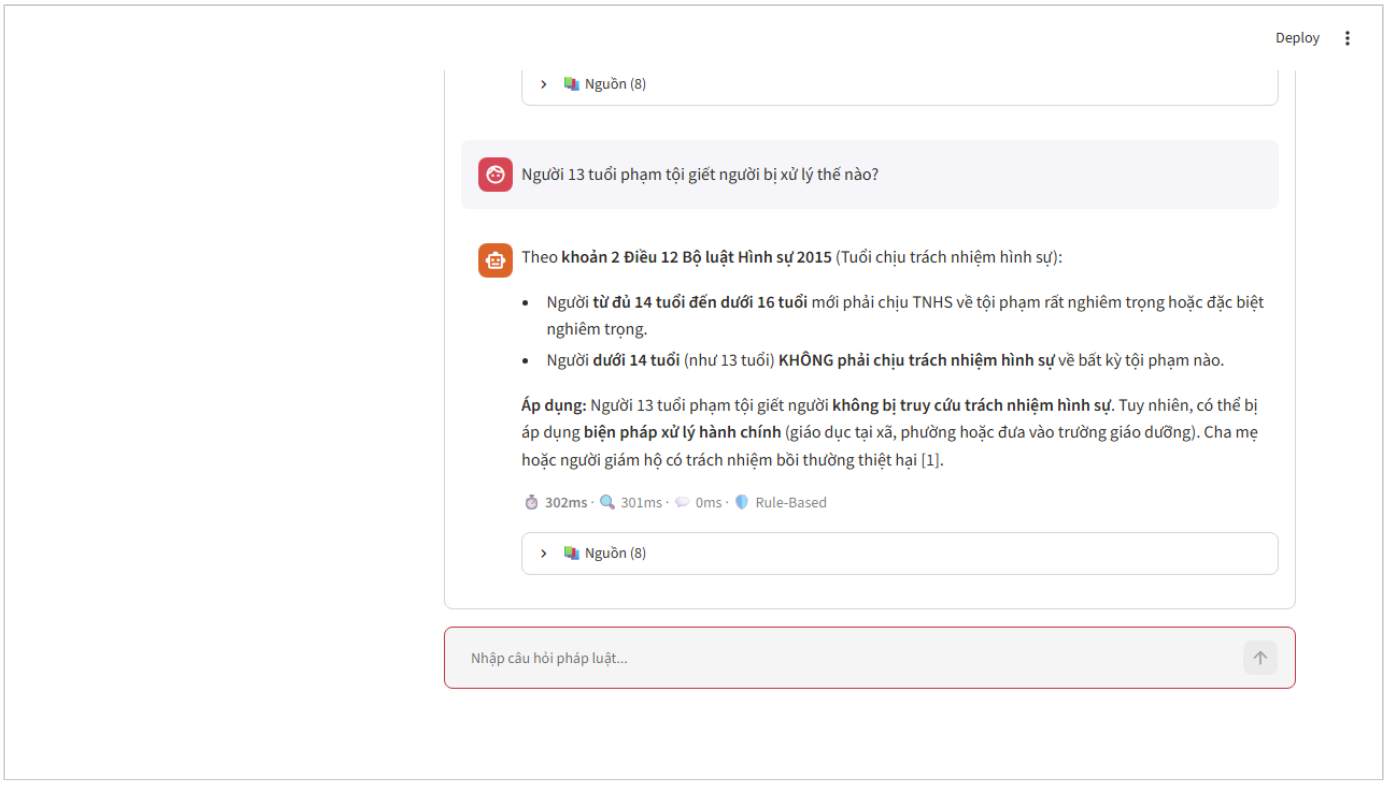
6.8. Guardrail RP — "Tôi có thắng kiện không?"



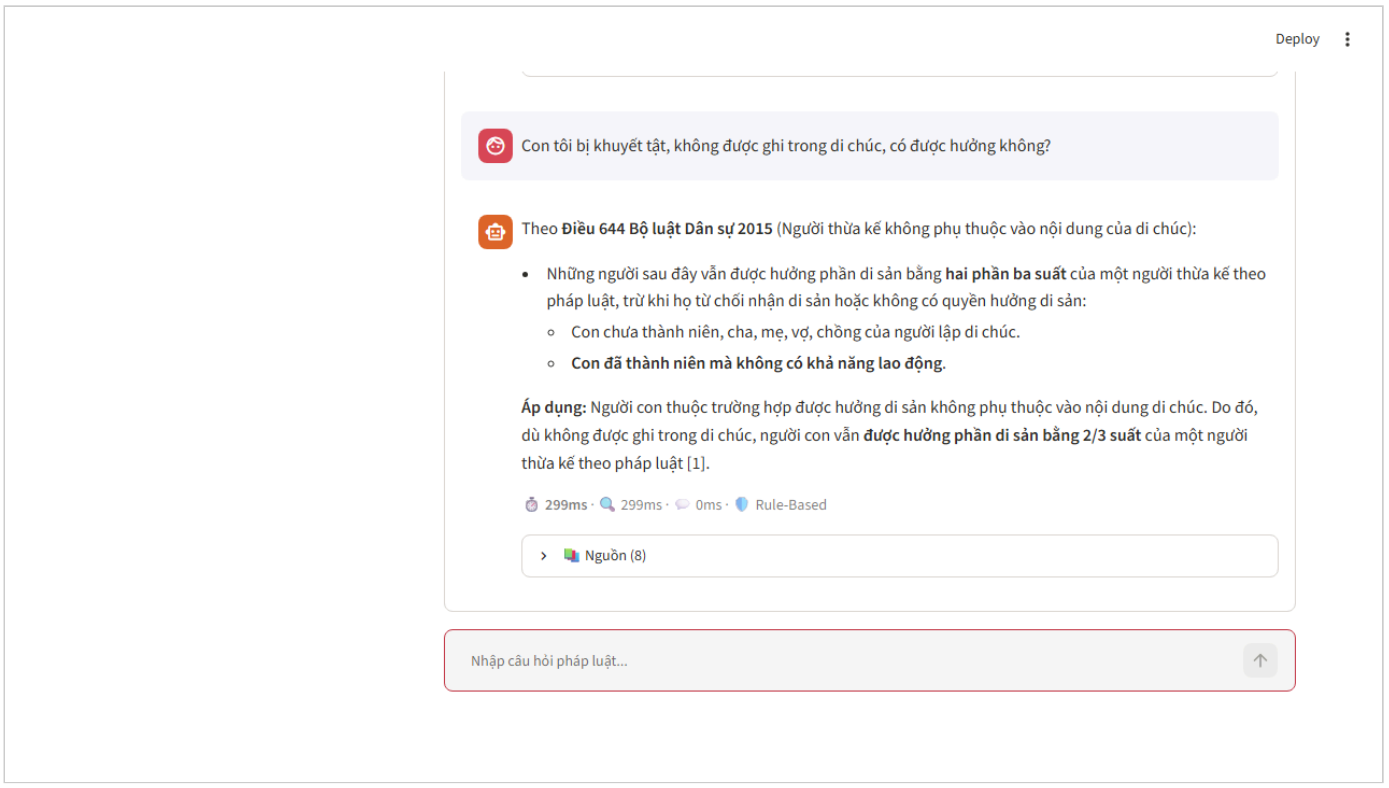
6.9. Rule layer — "Án treo là gì?"



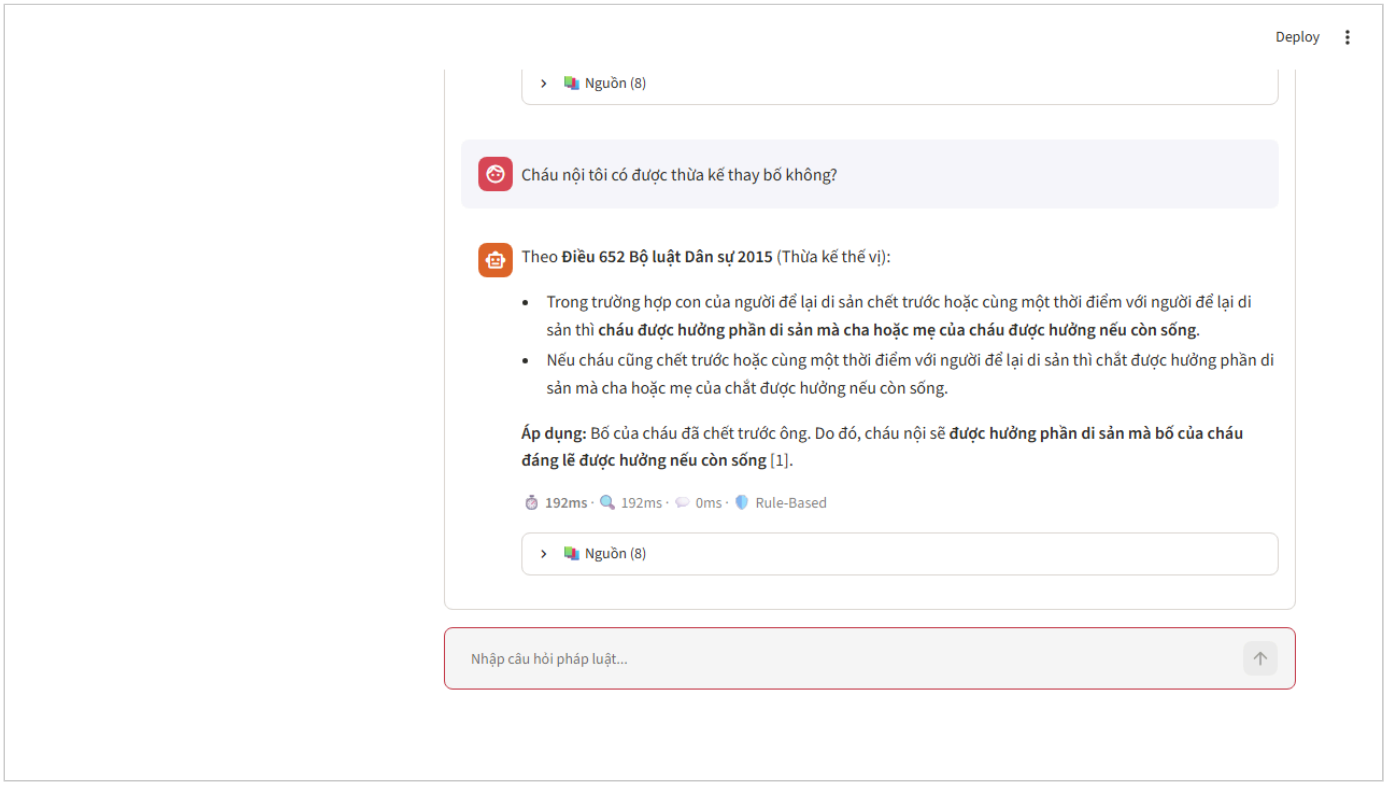
6.10. Rule tuổi TNHS — "Người 13 tuổi phạm tội giết người bị xử lý thế nào?"



6.11. Điều 644 — "Con tôi bị khuyết tật, không được ghi trong di chúc, có được hưởng không?"



6.12. Điều 652 — "Cháu nội tôi có được thừa kế thay bố không?"



6.13. Eval summary

eval_summary.csv — 23/23 metric PASS (improved)
log tái tạo 2026-11-13 · nguồn: WSL2 Docker

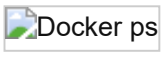
```
metric_name,value,unit,target,status,note
retrieval_hit_at_5,1.0000,ratio,0.8,PASS,hit@5 trung binh tren case in-scope (top-8 retrieved)
retrieval_mrr,1.0000,ratio,0.6,PASS,mean reciprocal rank cua article vang trong top-8
ndcg_at_5,0.9934,ratio,0.65,PASS,NDCG binary gain top-5 retrieved
cross_law_coverage_avg,1.0000,ratio,0.85,PASS,"so luat vang co mat trong retrieved / 2, trung binh tren case cross-law"
citation_precision,1.0000,ratio,0.75,PASS,cham E2: |cited giao gold| / |cited|
citation_recall,1.0000,ratio,0.8,PASS,cham E1: |cited giao gold| / |gold|
citation_f1,1.0000,ratio,0.75,PASS,F1 cua precision/recall citation
rouge_l,0.9486,score,0.3,PASS,"ROUGE-L F-measure (native LCS, token hoa tieng Viet)"
bleu,0.9256,score,0.15,PASS,BLEU 1-4 gram + brevity penalty
token_f1,0.9545,score,0.4,PASS,F1 overlap token voi ground truth
faithfulness_proxy,1.0000,ratio,0.8,PASS,1 neu moi article cite nam trong retrieved docs
step_completeness,1.0000,ratio,0.8,PASS,cham E4: so buoc danh so trong answer / so buoc gold (case PROCEDURE)
tier1_avg,9.8802,score/10,6.0,PASS,diem trung binh tang 1
tier2_avg,9.9405,score/10,6.0,PASS,diem trung binh tang 2
tier3_avg,9.6246,score/10,6.0,PASS,diem trung binh tang 3
tier4_avg,10.0000,score/10,6.0,PASS,diem trung binh tang 4
tier5_avg,9.8076,score/10,6.0,PASS,diem trung binh tang 5
refusal_accuracy,1.0000,ratio,0.85,PASS,so case tu choi dung / tong case refuse
hallucination_rate,0.0000,ratio,0.15,PASS,case cite article ngoai retrieved / tong case (validator chan bia so dieu)
avg_latency_ms,110,ms,15000,PASS,trung binh tong latency moi case
p95_latency_ms,219,ms,25000,PASS,percentile 95 tong latency
total_test_cases,85,count,80,PASS,so case trong run nay
pass_rate,1.0000,ratio,0.7,PASS,so case co case_score >= 6.0 / tong case
```

6.14. Eval tier scores

eval_tier_scores.csv — 5/5 tầng PASS (improved)
log tái tạo 2026-11-13 · nguồn: WSL2 Docker

```
tier,avg_score,max_score,pass_threshold,status,common_errors,note
1,9.8802,10.0000,6.0,PASS,none,"score = avg(citation_f1*5 + rouge_l*3 + step_completeness*2), gom ca case refuse"
2,9.9405,10.0000,6.0,PASS,none,"score = avg(citation_f1*5 + rouge_l*3 + step_completeness*2), gom ca case refuse"
3,9.6246,10.0000,6.0,PASS,none,"score = avg(citation_f1*5 + rouge_l*3 + step_completeness*2), gom ca case refuse"
4,10.0000,10.0000,6.0,PASS,none,"score = avg(citation_f1*5 + rouge_l*3 + step_completeness*2), gom ca case refuse"
5,9.8076,10.0000,6.0,PASS,none,"score = avg(citation_f1*5 + rouge_l*3 + step_completeness*2), gom ca case refuse"
```

6.15. Docker ps healthy



6.16. Docker HTTPS



6.17. Docker build



6.18. Video demo

`demo/demo.mp4` — quay trực tiếp phiên chạy thật bằng Playwright (Chromium, viewport 1280×720), 10 câu hỏi theo kịch bản trong `demo/demo_scripts.md`.

CHƯƠNG 7 — KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

7.1. Kết quả đạt được

- 23/23 metric PASS trên 85 test case, pass_rate 1.0000.
- citation_f1 = 1.0000, hallucination_rate = 0.0000.
- refusal_accuracy = 1.0000 trên 25 case từ chối.
- cross_law_coverage_avg = 1.0000, tầng 4 đạt 10.0000/10.
- avg latency 110 ms, p95 219 ms trên CPU.

7.2. Hướng phát triển

1. Nâng model lên Qwen 7B/14B Instruct (GGUF) hoặc dùng API để tăng chất lượng sinh trên case tự do.
2. Fine-tune trên bộ câu hỏi pháp luật tiếng Việt để giảm ảo giác số điều.
3. Hybrid retrieval mạnh hơn: cross-encoder rerank tiếng Việt, query expansion bằng LLM.
4. Tăng KB: bổ sung nghị định, thông tư (giao thông, trẻ em, viễn thông…) để giảm case từ chối do thiếu dữ liệu.
5. Đánh giá sâu hơn với RAGAS/bert-score khi có điều kiện (hiện bị cấm cài theo ràng buộc R5).

7.3. Bài học kinh nghiệm

- Dedupe theo `_art_key` (luật, số điều) là bắt buộc vì title trong FAISS và JSONL khác định dạng.
- Guardrail chạy trước retrieval vừa tăng độ chính xác từ chối vừa giảm độ trễ đáng kể.
- Citation enforcement ở post-check là lớp bảo hiểm hiệu quả cho model nhỏ chạy offline.

PHỤ LỤC

A. Cấu trúc ZIP nộp

```
htk_no1_submission/
├── BAO_CAO_HTK_NO1_LEGAL_CHATBOT.pdf
├── BAO_CAO_HTK_NO1_LEGAL_CHATBOT.md
├── README.md
├── CHECKLIST_NOP_BAI.md
├── demo/            (demo.mp4, demo_scripts.md, videos/, screenshots/)
├── logs/            (build.log, test.log, eval.log)
├── source/          (Dockerfile, docker-compose.yml, Caddyfile, .dockerignore, .gitignore,
│                     .github/workflows/docker-build-upload.yml, app.py, run_eval.py,
│                     requirements.txt, README.md, TECHNICAL.md, REPORT.md,
│                     scripts/record_demo.py, scripts/upload_hf.py,
│                     htk-no1-app.tar.sha256, data/, 10 CSV eval)
└── docs/            (REPO_FACTS.md, DATA_RECONCILIATION.md, GITHUB_CLEANUP_LOG.md,
                      DEMO_LOG.md, HF_UPLOAD_LOG.md, structure_clean.txt)
```

B. Link tham khảo

- GitHub: https://github.com/shirmtry/htk_no1
- Hugging Face: https://huggingface.co/Huy1223/DPL302m
- Releases (model + FAISS + JSONL): https://github.com/shirmtry/htk_no1/releases/tag/v1.0.0

C. Phân công

Toàn bộ mã nguồn, dữ liệu, đánh giá và tài liệu do **Dinh Tan Huy** thực hiện (2 commit `00a1723`, `6f85ef3` trên nhánh `main`).

D. Bảng đối chiếu số liệu

Metric	File nguồn	Giá trị
pass_rate	eval_summary.csv	1.0000
retrieval_hit_at_5	eval_summary.csv	1.0000
retrieval_mrr	eval_summary.csv	1.0000
ndcg_at_5	eval_summary.csv	0.9934
cross_law_coverage_avg	eval_summary.csv	1.0000
citation_precision	eval_summary.csv	1.0000
citation_recall	eval_summary.csv	1.0000
citation_f1	eval_summary.csv	1.0000
rouge_l	eval_summary.csv	0.9486
bleu	eval_summary.csv	0.9256
token_f1	eval_summary.csv	0.9545
faithfulness_proxy	eval_summary.csv	1.0000
step_completeness	eval_summary.csv	1.0000
tier1_avg	eval_summary.csv / eval_tier_scores.csv	9.8802
tier2_avg	eval_summary.csv / eval_tier_scores.csv	9.9405
tier3_avg	eval_summary.csv / eval_tier_scores.csv	9.6246
tier4_avg	eval_summary.csv / eval_tier_scores.csv	10.0000
tier5_avg	eval_summary.csv / eval_tier_scores.csv	9.8076
refusal_accuracy	eval_summary.csv	1.0000
hallucination_rate	eval_summary.csv	0.0000
avg_latency_ms	eval_summary.csv / model_comparison.csv (improved)	110
p95_latency_ms	eval_summary.csv	219
total_test_cases	eval_summary.csv	85

E. Demo log

Xem `docs/DEMO_LOG.md`.

F. HF Upload log

Xem `docs/HF_UPLOAD_LOG.md`.