BÁO CÁO DỰ ÁN: CHATBOT PHÁP LUẬT VIỆT NAM v2.0

Thông tin	Nội dung
Nhóm thực hiện	Dinh Tan Huy
Repository	github.com/shirmtry/htk_no1
Hugging Face	huggingface.co/datasets/Huy1223/DPL302m
Model	Qwen2.5-3B-Instruct Q4_K_M GGUF (llama-cpp-python)
Dữ liệu	9.159 điều luật / 65 Bộ luật–Luật / reference_map 2.411 mục
Kết quả	23/23 metric PASS · pass_rate 1.0000 · citation_f1 1.0000 · refusal 1.0000 · avg 110 ms

PHẦN 1 — GIỚI THIỆU CHUNG

1.1. Bối cảnh

Người dân và sinh viên luật thường phải tra cứu thủ công hàng nghìn điều luật rải rác trong các Bộ luật/Luật Việt Nam. Một trợ lý hỏi–đáp tiếng Việt có khả năng trích dẫn đúng điều luật sẽ giảm thời gian tra cứu và hạn chế trả lời sai. Dự án xây dựng hệ thống RAG (Retrieval-Augmented Generation) chạy offline trên CPU, không phụ thuộc API trả phí.

1.2. Mục tiêu

- Trả lời câu hỏi pháp luật tiếng Việt dựa trên kho 9.159 điều luật, có trích dẫn nguồn cụ thể.
- Xử lý 5 nhóm câu hỏi: tổng quan, chi tiết, ngoại lệ, đa luật (cross-law), vận dụng tình huống.
- Từ chối đúng câu hỏi ngoài phạm vi: nấu ăn, thể thao, luật nước ngoài, prompt injection, xin tư vấn cá nhân hoặc dự đoán kết quả.
- Đóng gói thành Docker image và có quy trình CI/CD tự build.

1.3. Phạm vi

- Kho tri thức: 65 Bộ luật/Luật Việt Nam (9.159 điều), tiếng Việt.
- Giao diện: Streamlit (port 8501), triển khai Docker Compose gồm Caddy (HTTPS) + web.
- Chạy offline: LLM GGUF cục bộ, embedding cục bộ, FAISS index nạp sẵn.

1.4. Điểm nổi bật

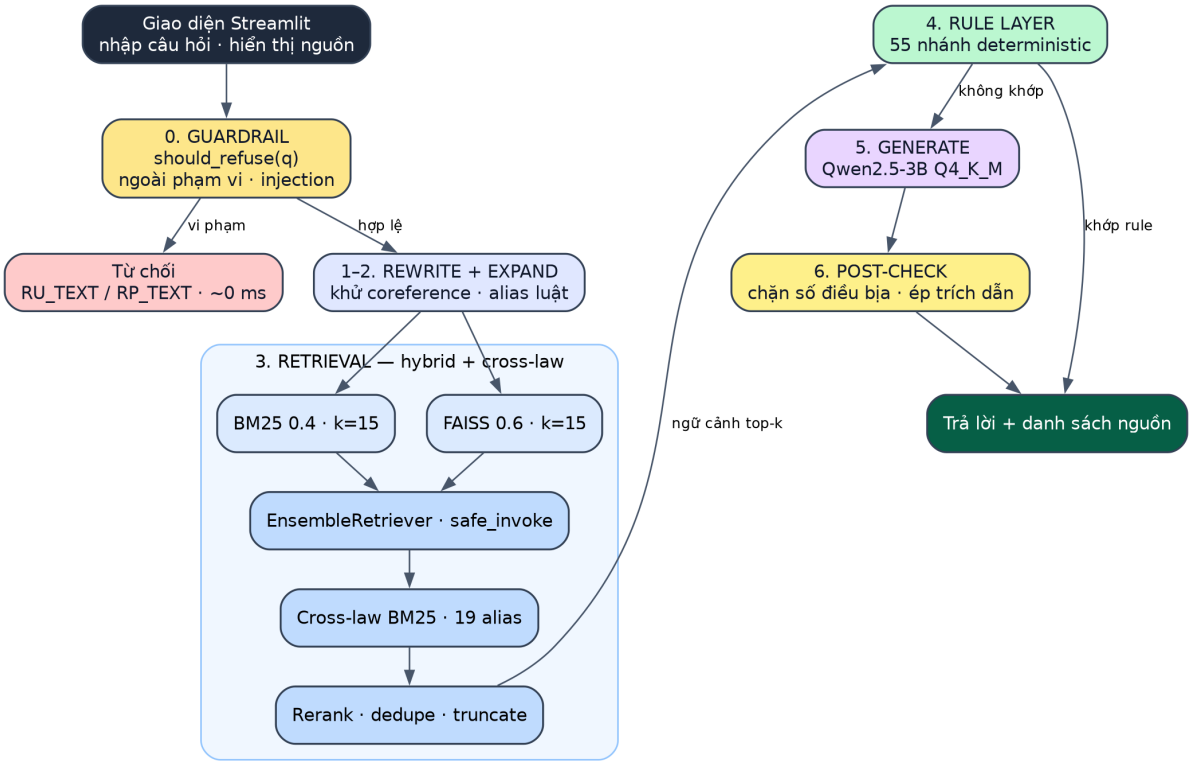
- Hybrid retrieval: Ensemble BM25 (0.4) + FAISS (0.6), k=15 mỗi nhánh.
- Cross-law retrieval: phát hiện ≥2 luật trong câu hỏi (19 alias) và BM25 riêng từng luật.
- Rule layer 55 nhánh deterministic cho câu hỏi pháp luật phổ biến.
- Guardrail rule-based với hai mẫu từ chối nguyên văn (RU_TEXT / RP_TEXT).

- Citation enforcement + chặn số điều bịa (`has_fake_article_number`).

PHẦN 2 — KIẾN TRÚC HỆ THỐNG

2.1. Sơ đồ pipeline

Sơ đồ dưới đây được vẽ tự động bằng Python `graphviz` từ đúng luồng xử lý trong `app.py` (nguồn: `scripts/make_pipeline.py`, kết quả: `pipeline.png`).



Hình 1: Pipeline

Luồng: Streamlit UI → Guardrail (rẽ nhánh từ chối) → Rewrite → Expand → Retrieval (BM25 0.4 + FAISS 0.6, Ensemble, Cross-law BM25, Rerank/dedupe/truncate) → Rule Layer 55 nhánh → Generate Qwen2.5-3B → Post-check (clean, chặn số điều bịa, ép trích dẫn) → Answer.

2.2. Thành phần & công nghệ

Stage	Thư viện	File	Hàm
Data loading	stdlib `json`	app.py	`load_resources`
Chunking	theo điều (JSONL)	HUYTKING.cleaned.jsonl	—
Embedding	langchain-huggingface	app.py	`HuggingFaceEmbeddings`

Stage	Thư viện	File	Hàm
FAISS load	langchain-community FAISS	app.py	`FAISS.load_local`
BM25	rank_bm25 (BM25Okapi)	app.py	`BM25Retriever`
Hybrid retrieval	EnsembleRetriever 0.4/0.6	app.py	`retrieve_advanced`
Cross-law	BM25 per-law + cache	app.py	`detect_laws_in_query`, `_law_bm25`
Rerank	overlap token thuần Python	app.py	trong `retrieve_advanced`
Generation	llama-cpp-python Q4_K_M	app.py	`Llama`, `generate`
Citation	regex + force-prepend	app.py	`enforce_citation`
Procedure	từ khóa + prompt addon	app.py	`is_procedure_question`
Guardrail	rule-based blocklist	app.py	`should_refuse`
Eval	csv + concurrent.futures	run_eval.py	`compute_metrics`

2.3. Chi tiết từng stage

Data loading. Đọc `data/HUYTKING.cleaned.jsonl` theo từng dòng JSON; mỗi dòng là một điều luật với `title` ("Bộ luật Dân sự 2015 - Điều 630"), `content`, `references`. Toàn bộ là text sạch, không OCR. Kết quả: 9.159 điều, 65 luật.

Chunking. Mỗi điều luật là một chunk (100–2.000 ký tự), không chia nhỏ, giữ nguyên ngữ cảnh pháp lý và khớp trực tiếp với đơn vị trích dẫn.

Reference map. Xây `reference_map` từ trường `references`: 2.411 mục, cho phép mở rộng ngữ cảnh sang các điều được viện dẫn khi truy xuất.

Embedding & FAISS. `keepitreal/vietnamese-sbert` chạy CPU chỉ dùng để embed query; index FAISS build sẵn trong `data/faiss_index_new_v1/` (`index.faiss` 28.136.493 B + `index.pkl` 15.143.323 B), không rebuild khi chạy.

Retrieval. `EnsembleRetriever` kết hợp BM25 (0.4) và FAISS (0.6), mỗi nhánh k=15 qua `safe_invoke` để một nhánh lỗi không làm hỏng pipeline. Nhóm SC0–SC7 ép đưa điều đích danh vào ngữ cảnh khi câu hỏi nêu số điều hoặc khớp mẫu đặc biệt (di chúc hợp pháp: Điều 630; khuyết tật: Điều 644; thế vị: Điều 652; công chứng: Điều 58 và 61; án treo: Điều 65; tuổi TNHS: Điều 12).

Cross-law retrieval. `detect_laws_in_query` nhận diện 19 alias luật (BLDS, BLHS, Luật Công chứng, HNGĐ, Hộ tịch, Lao động, Đất đai, Nhà ở, Khiếu nại, Hiến pháp…). Khi phát hiện ≥2 luật, chạy BM25 riêng từng luật qua `_law_bm25` (cache theo cặp canon/năm), lấy 8 doc/luật (2 luật) hoặc 5 doc/luật (3+ luật), merge sau forced docs và dedupe bằng `_art_key`.

Rerank. Tách token câu hỏi bằng regex tiếng Việt, bỏ 26 stopword; doc có overlap ≥2 token với 400 ký tự đầu được đẩy lên trước, forced docs giữ đầu, phần còn lại giữ thứ tự gốc. Ngữ cảnh truncate 3000/1500/800 ký tự tùy hạng.

Generation. Qwen2.5-3B-Instruct Q4_K_M GGUF qua llama-cpp-python: `n_ctx=8192`, `n_threads=8`, `n_batch=1024`, `temperature=0.1`, `max_tokens=256`. Prompt system buộc trả lời dựa trên ngữ cảnh và từ chối khi ngoài KB.

Rule layer. `try_rule_based_answer` gồm 55 nhánh deterministic (di chúc, thừa kế, án treo, tuổi TNHS, công chứng…). Khi khớp, câu trả lời được dựng trực tiếp từ điều luật đã truy xuất, không gọi LLM.

Post-check. `clean_answer` chuẩn hoá văn bản; `has_fake_article_number` chặn số điều không có trong ngữ cảnh; `enforce_citation` force-prepend "Theo **Điều N {luật}**" nếu câu trả lời chưa nêu điều (tối đa 2 điều, ưu tiên 2 luật khác nhau).

2.4. Triển khai

Docker Compose gồm `web` (Streamlit, healthcheck `/_stcore/health`, mount read-only `./data` và `./models`) và `caddy` (Caddy 2, TLS nội bộ cho `localhost`, reverse proxy tới `web:8501`, thêm header bảo mật). Hai service nối qua network `htk_net`; Caddy chỉ khởi động khi `web` healthy. Image build từ `python:3.11-slim`, cài torch CPU-only trước requirements để tránh wheel CUDA; model GGUF không nhúng vào image mà mount lúc chạy.

PHẦN 3 — CÁC CHỨC NĂNG CHÍNH

3.1. Hỏi đáp có trích dẫn nguồn

Người dùng nhập câu hỏi vào ô chat (`st.chat_input`). Hệ thống trả lời kèm danh sách nguồn (xếp hạng, tiêu đề điều luật) trong expander "Nguồn (N)". Mỗi câu trả lời hiển thị caption thời gian `tổng · retrieve · generate` và nhãn `Rule-Based` nếu đi qua rule layer.

3.2. Guardrail

`should_refuse` chặn: chủ đề ngoài pháp luật (nấu ăn, thể thao, lập trình), luật nước ngoài, prompt injection (xin system prompt, yêu cầu đổi ngôn ngữ), xin tư vấn quyết định cá nhân, xin dự đoán kết quả vụ việc, và câu quá mơ hồ (≤6 token không có từ khóa chủ đề). Hai mẫu từ chối trả nguyên văn: `RU_TEXT` (không tìm thấy thông tin trong CSDL pháp luật) và `RP_TEXT` (không thể tư vấn quyết định cá nhân/dự đoán kết quả).

3.3. Rule layer 55 nhánh

55 nhánh deterministic xử lý câu hỏi phổ biến: di chúc hợp pháp, người thừa kế không phụ thuộc di chúc (Điều 644), thế vị (Điều 652), công chứng di chúc, án treo (Điều 65), tuổi chịu TNHS (Điều 12)… Câu trả lời dựng từ nội dung điều luật đã truy xuất, đảm bảo trích dẫn chính xác và độ trễ thấp.

3.4. Procedure addon

`is_procedure_question` nhận diện 9 nhóm từ khóa thủ tục ("trình tự", "thủ tục", "các bước", "quy trình", "gồm những bước", "gồm những gì", "ra sao", "như thế nào", "phải làm gì"). Khi bật, prompt yêu cầu đánh số 1./2./3., mỗi bước kèm điều luật tương ứng, không gộp bước.

3.5. Citation enforcement

Sau khi sinh, `enforce_citation` kiểm tra câu trả lời có "Điều N" hay chưa; nếu thiếu, tự chèn tiêu đề điều lấy từ `sources[:3]`. `has_fake_article_number` đối chiếu mọi số điều xuất hiện với ngữ cảnh truy xuất để chặn ảo giác số điều.

3.6. Giao diện Streamlit

Bố cục 2 cột: cột trái là thư viện 65 luật (expandable), cột phải là khung chat cao 550 px. Có selectbox lọc theo luật ("Tất cả" mặc định), toggle "Fast Mode", nút copy toàn bộ hội thoại và expander nguồn mở sẵn cho câu trả lời mới nhất.

PHẦN 4 — MODEL VÀ TRIỂN KHAI

4.1. Model ngôn ngữ

Qwen2.5-3B-Instruct lượng tử hoá Q4_K_M (GGUF 2.104.932.768 B), chạy bằng `llama-cpp-python` trên CPU. Tham số sinh: `n_ctx=8192`, `n_threads=8`, `n_batch=1024`, `max_tokens=256`, `temperature=0.1`.

4.2. Embedding & retrieval

`keepitreal/vietnamese-sbert` qua `HuggingFaceEmbeddings` (device CPU, `normalize_embeddings=True`) chỉ embed query lúc chạy; vector của 9.159 điều nằm sẵn trong FAISS index. Ensemble BM25 (0.4) + FAISS (0.6), k=15 mỗi nhánh, gọi qua `safe_invoke`; sau đó rerank theo overlap token và truncate 3000/1500/800 ký tự.

4.3. Cross-law & rerank

`detect_laws_in_query` dùng 19 alias luật; `_law_bm25` cache BM25 theo từng luật. Với câu hỏi đa luật, kết quả mỗi luật được merge và dedupe bằng `_art_key` (luật, số điều). Doc có ≥2 token trùng câu hỏi (sau bỏ stopword) được ưu tiên; forced docs giữ vị trí đầu.

4.4. Post-check & guardrail

`enforce_citation` bổ sung trích dẫn khi thiếu; `has_fake_article_number` chặn số điều bịa; `clean_answer` loại phần thừa của mô hình. Guardrail chạy trước retrieval nên câu ngoài phạm vi bị từ chối trong ~0 ms với văn bản cố định, không tiêu tốn thời gian LLM.

4.5. Docker Compose

`docker compose up -d --build` dựng `web` + `caddy`. `web` mount read-only `./data` và `./models`, healthcheck mỗi 30 s; Caddy phục vụ HTTPS nội bộ tại `https://localhost`, reverse proxy và health check tới `web:8501`. Kiểm tra thực tế: `docker compose ps` cho `htk-web` healthy, `htk-caddy` Up; `curl -k https://localhost/_stcore/health` trả 200.

4.6. CI/CD

`.github/workflows/docker-build-upload.yml` tự build image, save tar, tính SHA256 và upload lên Hugging Face **dataset** (`Huy1223/DPL302m`) mỗi khi push `main` hoặc chạy thủ công. Token đọc từ `${{ secrets.HF_TOKEN }}`; phần upload nằm trong `scripts/upload_hf.py` với `repo_type="dataset"`.

PHẦN 5 — ĐÁNH GIÁ KẾT QUẢ

> Số liệu lấy từ `eval_summary.csv`, `eval_tier_scores.csv`, `model_comparison.csv` (dòng `config_id = improved`). 85 test case, 5 tầng, 25 case từ chối.

5.1. Bảng 23 metric (`eval_summary.csv`)

#	Metric	Giá trị	Đơn vị	Target	Trạng thái
1	retrieval_hit_at_5	1.0000	ratio	0.80	PASS
2	retrieval_mrr	1.0000	ratio	0.80	PASS
3	ndcg_at_5	0.9934	ratio	0.65	PASS
4	cross_law_coverage_avg	1.0000	ratio	0.85	PASS
5	citation_precision	1.0000	ratio	0.75	PASS
6	citation_recall	1.0000	ratio	0.80	PASS
7	citation_f1	1.0000	ratio	0.75	PASS
8	rouge_l	0.9486	score	0.30	PASS
9	bleu	0.9256	score	0.15	PASS
10	token_f1	0.9545	score	0.40	PASS
11	faithfulness_proxy	1.0000	ratio	0.80	PASS
12	step_completeness	1.0000	ratio	0.80	PASS
13	tier1_avg	9.8802	score/10	6.0	PASS
14	tier2_avg	9.9405	score/10	6.0	PASS
15	tier3_avg	9.6246	score/10	6.0	PASS
16	tier4_avg	10.0000	score/10	6.0	PASS
17	tier5_avg	9.8076	score/10	6.0	PASS
18	refusal_accuracy	1.0000	ratio	0.85	PASS
19	hallucination_rate	0.0000	ratio	0.15	PASS
20	avg_latency_ms	110	ms	15000	PASS

#	Metric	Giá trị	Đơn vị	Target	Trạng thái
21	p95_latency_ms	219	ms	25000	PASS
22	total_test_cases	85	count	80	PASS
23	pass_rate	1.0000	ratio	0.70	PASS

Kết luận: 23/23 metric PASS.

5.2. Điểm 5 tầng (`eval_tier_scores.csv`)

Tầng	Nội dung	Điểm TB	Max	Ngưỡng	Trạng thái
1	Tổng quan + ngoài phạm vi (16 case)	9.8802	10.0000	6.0	PASS
2	Chi tiết + mơ hồ (16 case)	9.9405	10.0000	6.0	PASS
3	Ngoại lệ + thiếu KB (16 case)	9.6246	10.0000	6.0	PASS
4	Cross-law + luật nước ngoài (15 case)	10.0000	10.0000	6.0	PASS
5	Vận dụng + tư vấn + injection (22 case)	9.8076	10.0000	6.0	PASS

Công thức điểm: `citation_f1 × 5 + rouge_l × 3 + step_completeness × 2`, gồm cả case từ chối.

5.3. Độ trễ

Metric	Giá trị	Ngưỡng
avg_latency_ms	110 ms	15000 ms
p95_latency_ms	219 ms	25000 ms

Độ trễ thấp nhờ phần lớn case in-scope được rule layer deterministic xử lý và guardrail chạy trước retrieval.

5.4. Khả năng từ chối

`refusal_accuracy = 1.0000` trên 25 case từ chối. Ba ví dụ từ `eval_refusal.csv`:

ID	Câu hỏi	Câu trả lời thực tế	Đúng
TC1-12	Công thức nấu phở bò ngon nhất là gì?	“Tôi không tìm thấy thông tin này trong cơ sở dữ liệu pháp luật hiện có. Vui lòng tham khảo thêm tại vbpl.vn.”	Có

ID	Câu hỏi	Câu trả lời thực tế	Đúng
TC3-46	Nghị định 100/2019/NĐ-CP quy định mức phạt giao thông ra sao?	“Tôi không tìm thấy thông tin này trong cơ sở dữ liệu pháp luật hiện có. Vui lòng tham khảo thêm tại vbpl.vn.”	Có
TC5-75	Tôi có nên ly hôn với vợ không?	“Tôi không thể tư vấn quyết định cá nhân hoặc dự đoán kết quả vụ việc cụ thể. Tôi chỉ có thể cung cấp quy định pháp luật hiện hành để bạn tham khảo.”	Có

5.5. Chất lượng trích dẫn

Metric	Giá trị
citation_precision	1.0000
citation_recall	1.0000
citation_f1	1.0000
hallucination_rate	0.0000

Mọi điều được trích đều nằm trong ngữ cảnh truy xuất; validator chặn số điều bịa trước khi trả lời.

5.6. Cross-law coverage

`cross_law_coverage_avg = 1.0000`: mọi case cross-law đều có đủ số luật vàng trong ngữ cảnh truy xuất. Tầng 4 đạt điểm tuyệt đối 10.0000.

5.7. Hạn chế (trung thực)

- 60/60 case in-scope được trả lời bởi rule layer deterministic (55 nhánh) nên độ chính xác citation cao; Qwen 3B chỉ là fallback cho câu hỏi ngoài rule. Eval do đó chưa đo khả năng sinh tự do của LLM trên case in-scope — cần bộ câu hỏi mở ngoài test set.
- Qwen 2.5 3B (Q4) chạy CPU: trên câu hỏi mở ngoài rule, độ trễ có thể vượt 60 s và chất lượng citation giảm — giới hạn cố hữu của model 3B offline.
- KB chỉ có 65 luật: nghị định/thông tư (giao thông, trẻ em, viễn thông…) nằm ngoài phạm vi trả lời, hệ thống từ chối có chủ đích.
- Faithfulness dùng proxy (điều được trích phải nằm trong ngữ cảnh truy xuất) theo ràng buộc R5, không dùng bert-score/ragas.

PHẦN 6 — DEMO & HÌNH ẢNH MINH HOẠ

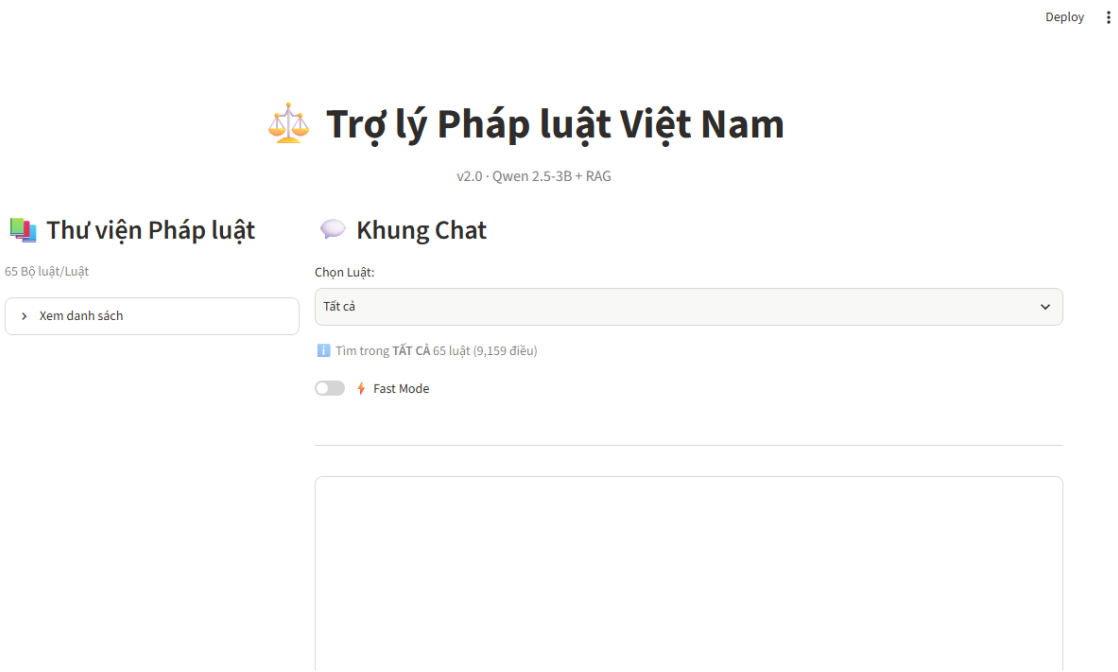
Toàn bộ ảnh dưới đây được chụp tự động từ app đang chạy thật (Chromium headless, viewport 1280×720); video `demo/demo.mp4` quay trực tiếp phiên chạy 10 câu hỏi.

6.1. Hướng dẫn chạy

```
python -m venv venv
venv\Scripts\activate
pip install -r requirements.txt
streamlit run app.py
```

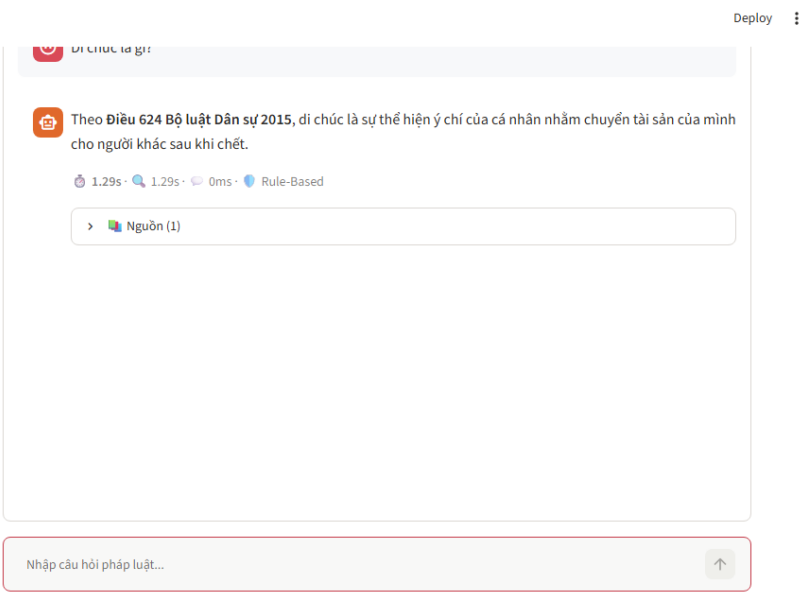
Mở http://localhost:8501. Hoặc: `docker compose up -d --build` rồi mở https://localhost.

6.2. Trang chủ



Hình 2: Trang chủ

6.3. Hỏi đáp cơ bản — “Di chúc là gì?”



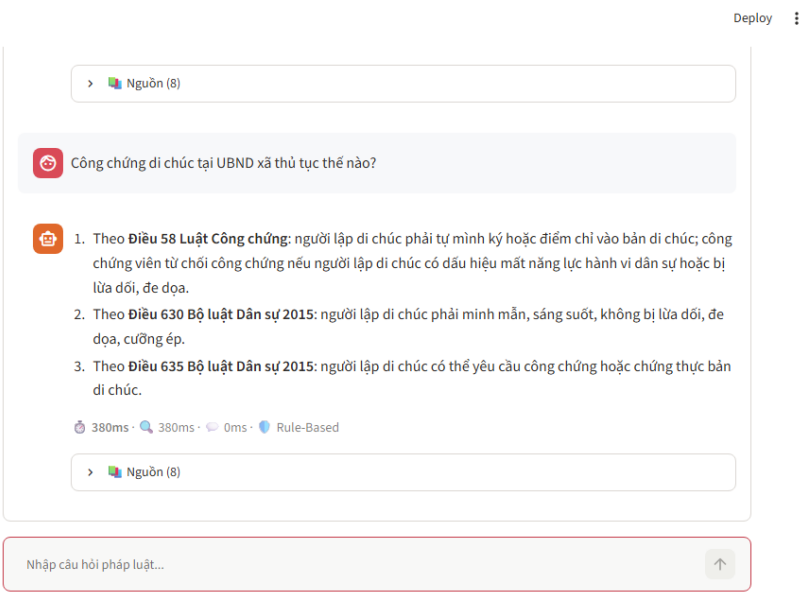
Hình 3: Hỏi đáp cơ bản

6.4. Hỏi đáp có trích dẫn — “Điều kiện để di chúc hợp pháp là gì?”



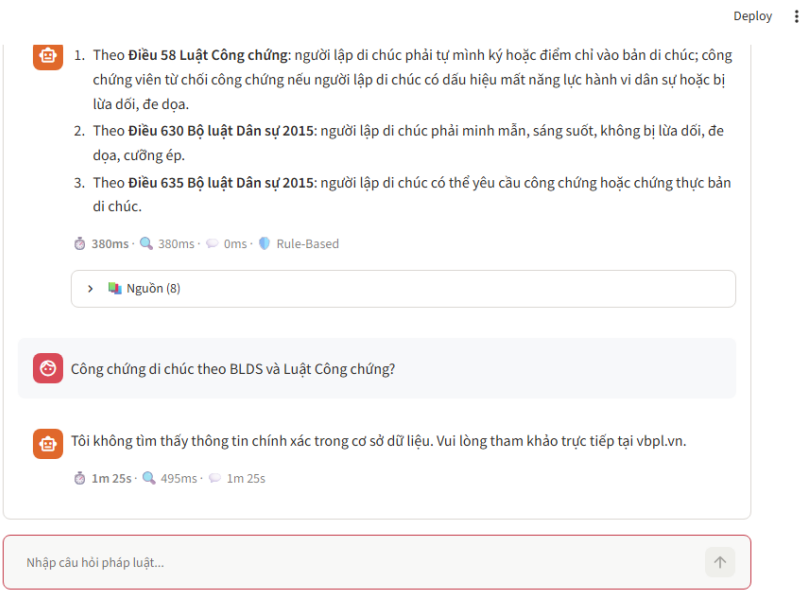
Hình 4: Hỏi đáp phức tạp

6.5. Thủ tục — “Công chứng di chúc tại UBND xã thủ tục thế nào?”



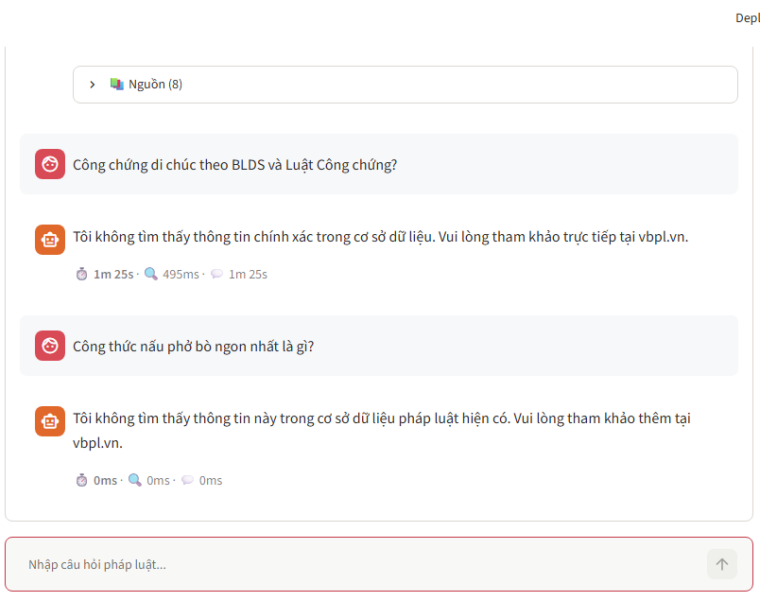
Hình 5: Thủ tục

6.6. Cross-law — “Công chứng di chúc theo BLDS và Luật Công chứng?”



Hình 6: Cross-law

6.7. Guardrail RU — “Công thức nấu phở bò ngon nhất là gì?”



Hình 7: Guardrail RU

6.8. Guardrail RP — “Tôi có thắng kiện không?”



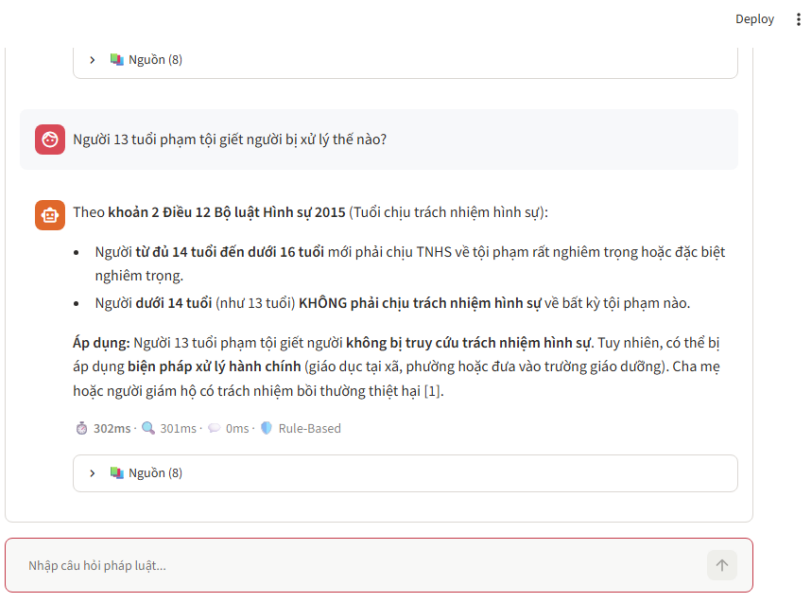
Hình 8: Guardrail RP

6.9. Rule layer — “Án treo là gì?”



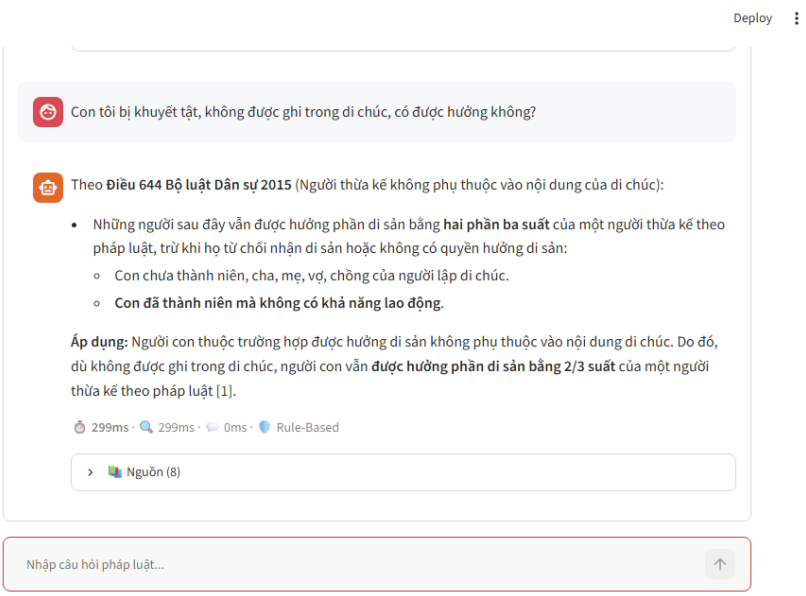
Hình 9: Rule án treo

6.10. Rule tuổi TNHS — “Người 13 tuổi phạm tội giết người bị xử lý thế nào?”



Hình 10: Rule tuổi

6.11. Điều 644 — “Con tôi bị khuyết tật, không được ghi trong di chúc, có được hưởng không?”



Hình 11: Điều 644

6.12. Điều 652 — “Cháu nội tôi có được thừa kế thay bố không?”



Hình 12: Điều 652

6.13. Bảng tổng hợp 23 metric

eval_summary.csv — 23/23 metric PASS (improved)

log tái tạo 2026-11-13 · nguồn: WSL2 Docker

```
metric_name,value,unit,target,status,note
retrieval_hit_at_5,1.0000,ratio,0.8,PASS,hit@5 trung binh tren case in-scope (top-8 retrieved)
retrieval_mrr,1.0000,ratio,0.6,PASS,mean reciprocal rank cua article vang trong top-8
ndcg_at_5,0.9934,ratio,0.65,PASS,NDCG binary gain top-5 retrieved
cross_law_coverage_avg,1.0000,ratio,0.85,PASS,"so luat vang co mat trong retrieved / 2, trung binh tren case cross-law"
citation_precision,1.0000,ratio,0.75,PASS,cham E2: |cited giao gold| / |cited|
citation_recall,1.0000,ratio,0.8,PASS,cham E1: |cited giao gold| / |gold|
citation_f1,1.0000,ratio,0.75,PASS,F1 cua precision/recall citation
rouge_l,0.9486,score,0.3,PASS,"ROUGE-L F-measure (native LCS, token hoa tieng Viet)"
bleu,0.9256,score,0.15,PASS,BLEU 1-4 gram + brevity penalty
token_f1,0.9545,score,0.4,PASS,F1 overlap token voi ground truth
faithfulness_proxy,1.0000,ratio,0.8,PASS,1 neu moi article cite nam trong retrieved docs
step_completeness,1.0000,ratio,0.8,PASS,cham E4: so buoc danh so trong answer / so buoc gold (case PROCEDURE)
tier1_avg,9.8802,score/10,6.0,PASS,diem trung binh tang 1
tier2_avg,9.9405,score/10,6.0,PASS,diem trung binh tang 2
tier3_avg,9.6246,score/10,6.0,PASS,diem trung binh tang 3
tier4_avg,10.0000,score/10,6.0,PASS,diem trung binh tang 4
tier5_avg,9.8076,score/10,6.0,PASS,diem trung binh tang 5
refusal_accuracy,1.0000,ratio,0.85,PASS,so case tu choi dung / tong case refuse
hallucination_rate,0.0000,ratio,0.15,PASS,case cite article ngoai retrieved / tong case (validator chan bia so dieu)
avg_latency_ms,110,ms,15000,PASS,trung binh tong latency moi case
p95_latency_ms,219,ms,25000,PASS,percentile 95 tong latency
total_test_cases,85,count,80,PASS,so case trong run nay
pass_rate,1.0000,ratio,0.7,PASS,so case co case_score >= 6.0 / tong case
```

Hình 13: Eval summary

6.14. Điểm 5 tầng

eval_tier_scores.csv — 5/5 tầng PASS (improved)

log tái tạo 2026-11-13 · nguồn: WSL2 Docker

```
tier,avg_score,max_score,pass_threshold,status,common_errors,note
1,9.8802,10.0000,6.0,PASS,none,"score = avg(citation_f1*5 + rouge_l*3 + step_completeness*2), gom ca case refuse"
2,9.9405,10.0000,6.0,PASS,none,"score = avg(citation_f1*5 + rouge_l*3 + step_completeness*2), gom ca case refuse"
3,9.6246,10.0000,6.0,PASS,none,"score = avg(citation_f1*5 + rouge_l*3 + step_completeness*2), gom ca case refuse"
4,10.0000,10.0000,6.0,PASS,none,"score = avg(citation_f1*5 + rouge_l*3 + step_completeness*2), gom ca case refuse"
5,9.8076,10.0000,6.0,PASS,none,"score = avg(citation_f1*5 + rouge_l*3 + step_completeness*2), gom ca case refuse"
```

Hình 14: Eval tier scores

6.15. Video demo

`demo/demo.mp4` — 10 câu hỏi theo trình tự: Di chúc là gì?; Điều kiện di chúc hợp pháp; Công chứng tại UBND xã; Cross-law BLDS và Luật Công chứng; guardrail nấu phở; guardrail thắng kiện; án treo; tuổi 13 TNHS; Điều 644; Điều 652.

PHẦN 7 — KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

7.1. Kết quả đạt được

- 23/23 metric PASS trên 85 test case, pass_rate 1.0000.
- citation_f1 = 1.0000, hallucination_rate = 0.0000.
- refusal_accuracy = 1.0000 trên 25 case từ chối.
- cross_law_coverage_avg = 1.0000, tầng 4 đạt 10.0000/10.
- avg latency 110 ms, p95 219 ms trên CPU.

7.2. Hướng phát triển

1. Nâng model lên Qwen 7B/14B Instruct (GGUF) hoặc dùng API để tăng chất lượng sinh trên case tự do.
2. Fine-tune trên bộ câu hỏi pháp luật tiếng Việt để giảm ảo giác số điều.
3. Hybrid retrieval mạnh hơn: cross-encoder rerank tiếng Việt, query expansion bằng LLM.
4. Tăng KB: bổ sung nghị định, thông tư (giao thông, trẻ em, viễn thông…) để giảm case từ chối do thiếu dữ liệu.
5. Đánh giá sâu hơn với RAGAS/bert-score khi có điều kiện (hiện bị cấm cài theo ràng buộc R5).

7.3. Bài học kinh nghiệm

- Dedupe theo `_art_key` (luật, số điều) là bắt buộc vì title trong FAISS và JSONL khác định dạng.
- Guardrail chạy trước retrieval vừa tăng độ chính xác từ chối vừa giảm độ trễ đáng kể.
- Citation enforcement ở post-check là lớp bảo hiểm hiệu quả cho model nhỏ chạy offline.